8장 연습문제

문제 8.1. 함수의 편도함수 구하기

- (a) (곱의 미분) 다음 함수를 x, y에 대하여 편미분하시오.

$$f(x, y) = x^2 y^3 \tag{1}$$

- (b) (몫의 미분) 다음 함수를 x, y에 대하여 편미분하시오.

$$f(x, y) = \frac{x^2 + y}{x - y} \tag{2}$$

- (c) (합성 함수의 미분) 다음 함수를 x, y에 대하여 편미분하시오.

$$f(x, y) = \sin(xy) \tag{3}$$

문제 8.2. 다음 함수의 2차 편도함수는 $f_{xx}, f_{xy}, f_{yx}, f_{yy}$ 를 구하고 $f_{xy} = f_{yx}$을 확인하시오.

- (a) (다항식)

$$f(x, y) = 3x^2 y^3 - 4xy + 5y^2 \tag{4}$$

- (b) (지수함수의 합성: 체인룰)

$$f(x, y) = e^{xy^2} \quad (\text{지수부 } g(x, y) = xy^2) \tag{5}$$

문제 8.3. 일변수 테일러 전개를 활용하여 다음의 이변수함수의 테일러 전개를 구하여라.

- (a) $f(x, y) = e^{x+y}$ 를 $(0, 0)$에서 (3차까지).
- (b) e^{x+y}의 테일러 전개(중심 $(0, 0)$, 2차까지)를 사용하여, $x = 0.10,\ y = -0.02$일 때의 2차 테일러 근사값을 구하고 실제값과 비교하라.
- (c) $f(x, y) = \ln\big(1 + x + y\big)$ 를 $(0, 0)$에서 (3차까지)

문제 8.4. 이변수 테일러 전개 (2차까지)를 구하여라.

- (a) $f(x, y) = e^x \cos y$ 를 $(0, 0)$에서 (2차까지)
- (b) $f(x, y) = x^2 y^3$ 를 $(1, 1)$에서 (2차까지)

문제 8.5. 함수 $f : \mathbb{R}^2 \to \mathbb{R}$와 경로 벡터 $\boldsymbol{x}(t) \in \mathbb{R}^2$ 가 다음과 같이 주어졌을때, 벡터 속도 $\boldsymbol{x}'(t)$와 그래디언트 ∇f의 내적이 곡선 위에서의 합성함수 $\phi(t) := f(\boldsymbol{x}(t))$의 도함수 $\phi'(t)$와 같음을 보여라

- (a) $f(x, y) = x^2 y + \sin y$ 와 $\boldsymbol{x}(t) = \big(x_1(t), x_2(t)\big)^\top = (t^2,\ e^t)^\top$
- (b) $f(x, y) = \ln\big(1 + x^2 + y^2\big)$와 $\boldsymbol{x}(t) = \big(e^{2t},\ t^3\big)^\top$

문제 8.6. 다음 이변수 함수 예제로, 그래디언트가 (1) 함수값이 가장 빠르게 증가하는 방향, (2) 등고선에 수직인 방향임을 보여라.

- (a) $f(x, y) = x^2 + y^2$ (원형 등고선)
- (b) $f(x, y) = x^2 + 4y^2$ (타원형 등고선)

문제 8.7. 다음 함수의 볼록성 여부를 판단하라.

- (a) $f(x, y) = 3x^2 - 2y^2 + 2x - 4y + 1$
- (b) $f(x, y) = 3x^2 + y^2 + 4xy + x + 2y + 3$

8장 연습문제 해답

문제 8.1. 풀이

(a) 해설

$$f(x,y) = x^2y^3 \tag{6}$$

$$\frac{\partial f}{\partial x} = \frac{\partial}{\partial x}(x^2y^3) = 2xy^3 \tag{7}$$

$$\frac{\partial f}{\partial y} = \frac{\partial}{\partial y}(x^2y^3) = 3x^2y^2 \tag{8}$$

(b) 해설

$$f(x,y) = \frac{x^2+y}{x-y} \tag{9}$$

몫의 미분법을 사용한다:

$$\frac{\partial f}{\partial x} = \frac{(2x)(x-y)-(x^2+y)(1)}{(x-y)^2} = \frac{2x(x-y)-(x^2+y)}{(x-y)^2} \tag{10}$$

$$\frac{\partial f}{\partial y} = \frac{(1)(x-y)-(x^2+y)(-1)}{(x-y)^2} = \frac{(x-y)+(x^2+y)}{(x-y)^2} \tag{11}$$

(c) 해설

$$f(x,y) = \sin(xy) \tag{12}$$

체인 룰을 적용한다:

$$\frac{\partial f}{\partial x} = \cos(xy)\cdot\frac{\partial}{\partial x}(xy) = y\cos(xy) \tag{13}$$

$$\frac{\partial f}{\partial y} = \cos(xy)\cdot\frac{\partial}{\partial y}(xy) = x\cos(xy) \tag{14}$$

문제 8.2. 풀이

(a) $f(x,y) = 3x^2y^3 - 4xy + 5y^2$

1. 먼저 x에 대한 1차 편도함수:

$$f_x = \frac{\partial}{\partial x}(3x^2y^3 - 4xy + 5y^2) = (6xy^3) - (4y) + 0 = 6xy^3 - 4y \tag{15}$$

2. y에 대한 1차 편도함수:

$$f_y = \frac{\partial}{\partial y}(3x^2y^3 - 4xy + 5y^2) = (9x^2y^2) - (4x) + (10y) = 9x^2y^2 - 4x + 10y \tag{16}$$

3. 이제 2차 편도함수:

$$f_{xx} = \frac{\partial}{\partial x}(f_x) = \frac{\partial}{\partial x}(6xy^3 - 4y) = 6y^3 \tag{17}$$

$$f_{xy} = \frac{\partial}{\partial y}(f_x) = \frac{\partial}{\partial y}(6xy^3 - 4y) = 18xy^2 - 4 \tag{18}$$

$$f_{yx} = \frac{\partial}{\partial x}(f_y) = \frac{\partial}{\partial x}\left(9x^2y^2 - 4x + 10y\right) = 9 \cdot 2x \cdot y^2 \ - \ 4 \ + \ 0 = 18xy^2 - 4. \tag{19}$$

$$f_{yy} = \frac{\partial}{\partial y}(f_y) = \frac{\partial}{\partial y}(9x^2y^2 - 4x + 10y) = 18x^2y + 10 \tag{20}$$

따라서,

$$f_{xx} = 6y^3, \quad f_{xy} = f_{yx} = 18xy^2 - 4, \quad f_{yy} = 18x^2y + 10 \tag{21}$$

- (b) $f(x, y) = e^{xy^2}$

1. x에 대한 1차 편도함수:

$$f_x = \frac{\partial}{\partial x}(e^{xy^2}) = e^{xy^2} \cdot \frac{\partial}{\partial x}(xy^2) = e^{xy^2} \cdot (y^2) = y^2 e^{xy^2} \tag{22}$$

2. y에 대한 1차 편도함수:

$$f_y = \frac{\partial}{\partial y}(e^{xy^2}) = e^{xy^2} \cdot \frac{\partial}{\partial y}(xy^2) = e^{xy^2} \cdot (2xy) = 2xye^{xy^2} \tag{23}$$

3. 이제 2차 편도함수:

- f_{xx}:

$$\begin{aligned} f_{xx} &= \frac{\partial}{\partial x}(f_x) = \frac{\partial}{\partial x}(y^2 e^{xy^2}) = y^2 \cdot \frac{\partial}{\partial x}(e^{xy^2}) \\ &= y^2 \cdot \left(e^{xy^2} \cdot \frac{\partial}{\partial x}(xy^2)\right) = y^2 \cdot (e^{xy^2} \cdot y^2) = y^4 e^{xy^2} \end{aligned} \tag{24}$$

- f_{xy}:

$$\begin{aligned} f_{xy} &= \frac{\partial}{\partial y}(f_x) = \frac{\partial}{\partial y}(y^2 e^{xy^2}) = \underbrace{\frac{\partial}{\partial y}(y^2)}_{2y} \cdot e^{xy^2} + y^2 \cdot \frac{\partial}{\partial y}(e^{xy^2}) \\ &= 2ye^{xy^2} + y^2 \cdot (e^{xy^2} \cdot 2xy) = 2ye^{xy^2} + 2xy^3 e^{xy^2} = e^{xy^2}(2y + 2xy^3) \end{aligned} \tag{25}$$

- f_{yx}:

$$\begin{aligned} f_{yx} &= \frac{\partial}{\partial x}\left(2xy\, e^{xy^2}\right) = \underbrace{\frac{\partial}{\partial x}(2xy)}_{2y} \cdot e^{xy^2} \ + \ (2xy) \cdot \frac{\partial}{\partial x}\left(e^{xy^2}\right) \\ &= 2y\, e^{xy^2} \ + \ (2xy) \cdot \left(e^{xy^2} \cdot g_x\right) = 2y\, e^{xy^2} \ + \ (2xy) \cdot e^{xy^2} \cdot y^2 = e^{xy^2}\left(2y + 2xy^3\right) \end{aligned} \tag{26}$$

- f_{yy}:

$$\begin{aligned} f_{yy} &= \frac{\partial}{\partial y}(f_y) = \frac{\partial}{\partial y}(2xye^{xy^2}) = \underbrace{\frac{\partial}{\partial y}(2xy)}_{2x} \cdot e^{xy^2} + (2xy) \cdot \frac{\partial}{\partial y}(e^{xy^2}) \\ &= 2xe^{xy^2} + (2xy) \cdot (e^{xy^2} \cdot 2xy) = 2xe^{xy^2} + 4x^2y^2e^{xy^2} \end{aligned} \tag{27}$$

따라서,

$$f_{xx} = y^4 e^{xy^2}, \quad f_{xy} = f_{yx} = e^{xy^2}(2y + 2xy^3), \quad f_{yy} = 2xe^{xy^2} + 4x^2y^2e^{xy^2} \tag{28}$$

문제 8.3. 풀이

(a) $f(x, y) = e^{x+y}$ 를 $(0, 0)$에서 (3차까지)

여기서는 $u = x + y$. 1변수 급수 $e^u = 1 + u + \frac{u^2}{2} + \frac{u^3}{6} + O(u^4)$를 그대로 사용하면

$$\begin{aligned} e^{x+y} &= 1 + (x+y) + \frac{(x+y)^2}{2} + \frac{(x+y)^3}{6} + O(\|(x,y)\|^4) \\ &= 1 + (x+y) + \frac{x^2 + 2xy + y^2}{2} \\ &\quad + \frac{x^3 + 3x^2y + 3xy^2 + y^3}{6} + O(\|(x,y)\|^4). \end{aligned} \tag{29}$$

2차까지만 쓰면

$$\boxed{e^{x+y} \approx 1 + (x+y) + \tfrac{1}{2}(x^2 + 2xy + y^2).} \tag{30}$$

(b) e^{x+y}를 $(0, 0)$에서 2차로 근사. $x = 0.10,\ y = -0.02$이면

$$\begin{aligned} e^{x+y} &\approx 1 + (x+y) + \tfrac{1}{2}(x^2 + 2xy + y^2) \\ &= 1 + 0.08 + \tfrac{1}{2}(0.01 - 0.004 + 0.0004) \approx 1.0832. \end{aligned} \tag{31}$$

정확값 $e^{0.08} \approx 1.083287$와 매우 가깝습니다.

(c) $f(x, y) = \ln\big(1 + x + y\big)$ 를 $(0, 0)$에서 (3차까지)

역시 $u = x + y$, $\ln(1 + u) = u - \frac{u^2}{2} + \frac{u^3}{3} + O(u^4)$.

$$\begin{aligned} \ln(1 + x + y) &= (x+y) - \frac{(x+y)^2}{2} + \frac{(x+y)^3}{3} + O(\|(x,y)\|^4) \\ &= (x+y) - \frac{x^2 + 2xy + y^2}{2} + \frac{x^3 + 3x^2y + 3xy^2 + y^3}{3} + O(\|(x,y)\|^4). \end{aligned} \tag{32}$$

2차까지만 쓰면

$$\boxed{\ln(1 + x + y) \approx (x+y) - \tfrac{1}{2}(x^2 + 2xy + y^2).} \tag{33}$$

문제 8.4. 풀이

점 (a, b)에서 $f \in C^2$이면

$$\boxed{\begin{aligned} f(x,y) \ \approx\ & f(a,b) + f_x(a,b)\,\Delta x + f_y(a,b)\,\Delta y \\ & + \frac{1}{2}\Big[f_{xx}(a,b)\,(\Delta x)^2 + 2f_{xy}(a,b)\,\Delta x\,\Delta y + f_{yy}(a,b)\,(\Delta y)^2\Big] \\ & + R_2 \ \ (\text{보통 } R_2 = O(\|(\Delta x, \Delta y)\|^3)) \end{aligned}} \tag{34}$$

행렬(헤시안)으로 쓰면

$$f(a + \mathbf{h}) \approx f(a) + \nabla f(a)^\top \mathbf{h} + \tfrac{1}{2}\,\mathbf{h}^\top H_f(a)\,\mathbf{h}, \quad \mathbf{h} = (\Delta x, \Delta y)^\top. \tag{35}$$

(a) $f(x,y) = e^x \cos y$ 를 $(0,0)$에서 (2차까지)

1차·2차 편도함수:

$$\begin{aligned} &f(0,0) = 1, \quad f_x = e^x \cos y \Rightarrow f_x(0,0) = 1, \quad f_y = -e^x \sin y \Rightarrow f_y(0,0) = 0, \\ &f_{xx} = e^x \cos y \Rightarrow f_{xx}(0,0) = 1, \quad f_{xy} = -e^x \sin y \Rightarrow f_{xy}(0,0) = 0, \\ &f_{yy} = -e^x \cos y \Rightarrow f_{yy}(0,0) = -1. \end{aligned} \tag{36}$$

따라서

$$\boxed{e^x \cos y \approx 1 + x + \tfrac{1}{2}\left(x^2 - y^2\right).} \tag{37}$$

(참고로 급수로 계산해도 $e^x \approx 1 + x + \frac{x^2}{2}$, $\cos y \approx 1 - \frac{y^2}{2}$ 이므로 곱하면 동일한 2차식이 나옵니다.)

(b) $f(x,y) = x^2 y^3$ 를 $(1,1)$에서 (2차까지)

$\Delta x = x - 1,\ \Delta y = y - 1.$

값과 1차 미분:

$$f(1,1) = 1, \quad f_x = 2xy^3 \Rightarrow f_x(1,1) = 2, \quad f_y = 3x^2y^2 \Rightarrow f_y(1,1) = 3. \tag{38}$$

2차 미분(헤시안):

$$f_{xx} = 2y^3 \Rightarrow f_{xx}(1,1) = 2, \quad f_{xy} = 6xy^2 \Rightarrow f_{xy}(1,1) = 6, \quad f_{yy} = 6x^2y \Rightarrow f_{yy}(1,1) = 6. \tag{39}$$

따라서

$$\begin{aligned} f(x,y) &\approx 1 + 2\Delta x + 3\Delta y \\ &\quad + \frac{1}{2}\left[2(\Delta x)^2 + 2 \cdot 6\,\Delta x\,\Delta y + 6(\Delta y)^2\right] \\ &= 1 + 2\Delta x + 3\Delta y + \boxed{(\Delta x)^2 + 6\Delta x\,\Delta y + 3(\Delta y)^2}. \end{aligned} \tag{40}$$

문제 8.5. 풀이

(a): 함수와 경로를

$$f(x,y) = x^2 y + \sin y, \qquad \boldsymbol{x}(t) = \big(x_1(t), x_2(t)\big) = (t^2,\ e^t)^\top \tag{41}$$

로 둔다.

그래디언트와 속도 벡터

$$\nabla f(x,y) = \big(2xy,\ x^2 + \cos y\big)^\top, \qquad \boldsymbol{x}'(t) = \big(2t,\ e^t\big)^\top. \tag{42}$$

체인룰로 도함수

$$\begin{aligned} \frac{d}{dt} f(\boldsymbol{x}(t)) &= \nabla f(\boldsymbol{x}(t))^\top \boldsymbol{x}'(t) \\ &= \big(2 \cdot t^2 \cdot e^t,\ t^4 + \cos(e^t)\big) \cdot (2t,\ e^t)^\top \\ &= 4t^3 e^t + t^4 e^t + e^t \cos(e^t) \\ &= e^t\big(4t^3 + t^4 + \cos(e^t)\big). \end{aligned} \tag{43}$$

직접 합성해 확인

$$\begin{aligned}\phi(t) &= f(t^2, e^t) = t^4 e^t + \sin(e^t),\\ \phi'(t) &= e^t(4t^3 + t^4) + \cos(e^t)\cdot e^t = e^t\big(4t^3 + t^4 + \cos(e^t)\big)\end{aligned} \tag{44}$$

두 방법이 일치한다.

(b): 이번엔 로그 합성 예제를 보자.

$$f(x,y) = \ln\big(1 + x^2 + y^2\big), \quad \boldsymbol{x}(t) = \big(e^{2t},\, t^3\big)^\top. \tag{45}$$

그래디언트와 속도 벡터

$$\nabla f(x,y) = \left(\frac{2x}{1+x^2+y^2},\, \frac{2y}{1+x^2+y^2}\right)^\top, \quad \boldsymbol{x}'(t) = \big(2e^{2t},\, 3t^2\big)^\top. \tag{46}$$

체인룰로 도함수
분모를 $D(t) := 1 + e^{4t} + t^6$라 두면

$$\frac{d}{dt} f(\boldsymbol{x}(t)) = \frac{2e^{2t}}{D(t)}\cdot 2e^{2t} + \frac{2t^3}{D(t)}\cdot 3t^2 = \frac{4e^{4t} + 6t^5}{1 + e^{4t} + t^6}. \tag{47}$$

직접 합성해 확인

$$\phi(t) = \ln\big(1 + e^{4t} + t^6\big) \quad \Rightarrow \quad \phi'(t) = \frac{4e^{4t} + 6t^5}{1 + e^{4t} + t^6}. \tag{48}$$

역시 동일하게 나온다.

이 두 예제는 벡터 속도 $\boldsymbol{x}'(t)$와 그래디언트 ∇f의 내적이 곡선 위에서의 합성함수 도함수와 같다는 점을 분명히 보여 준다.

문제 8.6. 풀이

(a) : $f(x,y) = x^2 + y^2$ (원형 등고선)

- 그래디언트

$$\nabla f(x,y) = (2x,\, 2y)^\top. \tag{49}$$

- 가장 빠른 증가 방향: 단위벡터 $\boldsymbol{u}$ 방향의 방향도함수는

$$D_{\boldsymbol{u}} f := D(f(\boldsymbol{x}); \boldsymbol{u}) = \nabla f^\top \boldsymbol{u} = \|\nabla f\| \cos\theta \le \|\nabla f\|. \tag{50}$$

최댓값은 $\cos\theta = 1$, 즉 $\boldsymbol{u} = \dfrac{\nabla f}{\|\nabla f\|}$일 때 달성된다. 따라서 ∇f가 가장 빠른 증가 방향이다.

- 등고선에 수직: 등고선 $x^2 + y^2 = c$ (원)에서의 접선 기울기: $2x + 2y\,y' = 0 \Rightarrow y' = -x/y$. 접벡터 $\boldsymbol{t} = (1, -x/y)^\top$ 와 $\nabla f = (2x, 2y)^\top$ 의 내적은

$$\nabla f \cdot \boldsymbol{t} = 2x\cdot 1 + 2y\cdot(-x/y) = 0 \tag{51}$$

  으로 수직임을 확인.

(b): $f(x,y) = x^2 + 4y^2$ (타원형 등고선)

- 그래디언트

$$\nabla f(x,y) = (2x,\, 8y). \tag{52}$$

- 가장 빠른 증가 방향: 임의의 단위벡터 $\boldsymbol{u}$에 대해 $D_{\boldsymbol{u}} f = \nabla f \cdot \boldsymbol{u} \leq \|\nabla f\|$, 동등성은 $\boldsymbol{u} \parallel \nabla f$에서만 성립. 따라서 역시 ∇f 방향이 최급상승 방향.
- 등고선에 수직: 등고선 $x^2 + 4y^2 = c$ (타원)에서의 접선 기울기: $y' = -\dfrac{x}{4y} = -1$. 접벡터 $\boldsymbol{t} = (1, -\dfrac{x}{4y})^\top$ 와 $\nabla f = (2x, 8y)^\top$ 의 내적은

$$2x \cdot 1 + 8y \cdot \Big(-\frac{x}{4y} \Big) = 2x - 2x = 0 \tag{53}$$

이므로 수직이다.

문제 8.7. 풀이

(a) $f(x, y) = 3x^2 - 2y^2 + 2x - 4y + 1$

헤시안 계산

$$\nabla^2 f(x, y) = \begin{pmatrix} \partial_{xx} f & \partial_{xy} f \\ \partial_{yx} f & \partial_{yy} f \end{pmatrix} = \begin{pmatrix} 6 & 0 \\ 0 & -4 \end{pmatrix}. \tag{54}$$

이 행렬의 고유값은 6과 -4로, 하나는 양수 하나는 음수다. 따라서 PSD가 아니라 **부정부호(indefinite)** 이다.

→ 결론: 헤시안이 PSD가 아니므로 f는 볼록함수가 아니다.

(b) $f(x, y) = 3x^2 + y^2 + 4xy + x + 2y + 3$

헤시안 계산

$$\nabla^2 f(x, y) = \begin{pmatrix} 6 & 4 \\ 4 & 2 \end{pmatrix}. \tag{55}$$

대칭 2×2 행렬이 PSD이려면 첫 주대각 원소가 ≥ 0이고 행렬식이 ≥ 0이어야 한다. 여기서

$$a_{11} = 6 > 0, \qquad \det = 6 \cdot 2 - 4 \cdot 4 = 12 - 16 = -4 < 0. \tag{56}$$

행렬식이 음수이므로 헤시안은 **부정부호(indefinite)** 이다.

→ 결론: 헤시안이 PSD가 아니므로 f는 볼록함수가 아니다.

참고로 상수항과 선형항(예: $2x - 4y + 1$, $x + 2y + 3$)은 헤시안에 기여하지 않으므로, 볼록성 판단은 이차형식 부분(제곱·교차항)만으로 결정된다.

9장 연습문제

문제 9.1. 9.1 (True or False)

명제: 연속미분가능 $f : \mathbb{R}^2 \to \mathbb{R}$가 정확히 하나의 임계점 $\bar{x}$만 가지고, 그 $\bar{x}$가 국소 최소점이면, $\bar{x}$는 전역 최소점이다.

문제 9.2. Q-제곱 수렴성

수열 $x_k = 1 + (0.5)^{2^k}$ 가 1로 Q-제곱수렴함을 보여라.

문제 9.3. Rosenbrock류 함수 $f(x, y) = (1 - x)^2 + 5(y - x^2)^2$

- (a) 함수 f의 기울기(gradient)와 헤시안(Hessian) 행렬을 구하시오.
- (b) 함수 f의 임계점(critical point)을 구하고, 각 점을 국소 최소(local minimum), 국소 최대(local maximum), 안장점(saddle point)으로 분류하시오.

문제 9.4. 다항식 예제 $f(x, y) = 4y^3 + x^2 - 12y^2 - 36y + 2$

- (a) 함수 f의 기울기(gradient)와 헤시안(Hessian) 행렬을 구하시오.
- (b) 함수 f의 임계점(critical point)을 구하고, 각 점을 국소 최소(local minimum), 국소 최대(local maximum), 안장점(saddle point)으로 분류하시오.

문제 9.5. 입력이 중심화되어 있을 때(각 특성의 평균이 0) 릿지(ridge) 문제는 다음과 같은 행렬 형식으로 쓸 수 있다:

$$\min_{\boldsymbol{\beta}} RSS_\lambda(\boldsymbol{\beta}) = (\boldsymbol{y} - \boldsymbol{X}\boldsymbol{\beta})^\top (\boldsymbol{y} - \boldsymbol{X}\boldsymbol{\beta}) + \lambda\, \boldsymbol{\beta}^\top \boldsymbol{\beta}. \tag{1}$$

이 최소화 문제의 해 $\hat{\boldsymbol{\beta}}^{\text{ridge}}$를 구하시오.

문제 9.6. $x_1, x_2, \ldots, x_n$이 서로 독립이고 동일한 분포를 따르는 정규분포

$$N(\mu, \nu = \sigma^2) = (2\pi\nu)^{-1/2} \exp\left[-\frac{1}{2\nu}(x - \mu)^2\right] \tag{2}$$

로부터의 임의 표본이라고 하자. μ, ν에 대한 최대 로그가능도 추정량을 구하고자 한다.

- (a) 로그가능도 $f(\mu, \nu) = \ln p(x_1, x_2, \ldots, x_n \mid \mu, \nu)$를 계산하시오.
- (b) f의 그래디언트를 구하고, 임계점 (μ^*, ν^*)를 계산하시오.
- (c) (μ^*, ν^*)에서의 f의 헤시안(Hessian)을 구하고, (μ^*, ν^*)가 전역 최댓값(global maximum)임을 보이시오.

문제 9.7. (기대값 관점의 편향)

Adam의 1차·2차 모멘트 추정량을

$$v_k = \gamma_1 v_{k-1} + (1-\gamma_1) g_k, \qquad r_k = \gamma_2 r_{k-1} + (1-\gamma_2) g_k^2, \tag{3}$$

(초깃값 $v_0 = r_0 = 0$)로 둔다. $\{g_k\}$가 정상적(stationary)이고 $\mathbb{E}[g_k] = m,\ \mathbb{E}[g_k^2] = s_2$라 가정하라.

- (a) $v_k,\ r_k$의 기댓값 $\mathbb{E}[v_k], \mathbb{E}[r_k]$를 구하고, 이들이 각각 $(1-\gamma_1^k)m,\ (1-\gamma_2^k)s_2$로 과소 추정됨을 보여라.
- (b) 편향 보정량

$$\hat{v}_k = \frac{v_k}{1-\gamma_1^k}, \qquad \hat{r}_k = \frac{r_k}{1-\gamma_2^k} \tag{4}$$

이 각각 $m,\ s_2$의 불편 추정량(기대값이 참값)임을 보여라.

- (c) (가중합 표현과 편향의 원인) 귀납으로

$$v_k = (1-\gamma_1)\sum_{t=1}^{k} \gamma_1^{k-t} g_t, \qquad r_k = (1-\gamma_2)\sum_{t=1}^{k} \gamma_2^{k-t} g_t^2 \tag{5}$$

를 보이라. 이때 계수들의 합이 각각 $1-\gamma_1^k,\ 1-\gamma_2^k$임을 확인하고, 이 합이 1보다 작기 때문에 초기에 과소 추정이 발생함을 설명하라.

문제 9.8. (수치 예: 초기에 왜 보정이 중요한가)

문제 9.7에서 $\gamma_1 = 0.9,\ \gamma_2 = 0.999$, 그리고 $g_t \equiv 1$ (상수 그래디언트)라고 하자.

- (a) $k = 1$에서 $v_1,\ r_1$과 $\hat{v}_1,\ \hat{r}_1$을 계산하라.
- (b) Adam의 한 스텝 크기(스칼라) 비율

$$\text{step}_{\text{uncorr}} = \frac{v_k}{\sqrt{r_k} + \delta}, \qquad \text{step}_{\text{corr}} = \frac{\hat{v}_k}{\sqrt{\hat{r}_k} + \delta} \tag{6}$$

에서 $\delta \to 0$으로 두고

$$\frac{\text{step}_{\text{uncorr}}}{\text{step}_{\text{corr}}} = \frac{v_k/\sqrt{r_k}}{\hat{v}_k/\sqrt{\hat{r}_k}} = \frac{1-\gamma_1^k}{\sqrt{1-\gamma_2^k}} \tag{7}$$

임을 보이라. $k = 1$에 수치를 대입해 초기 스텝이 보정 없이 더 커질 수 있음을 확인하라.

9장 연습문제 해답

문제 9.1. 풀이

- **정답:** 거짓(False).

  이유: 국소 정보(한 점에서의 최소성)만으로 전역 최소성을 보장하려면 보통 **볼록성** 같은 전역 구조가 필요하다. 비볼록 함수의 경우, 유일한 임계점이 국소 최소점이어도, 함수값이 멀리 떨어진 곳에서 더 작아지도록 (예: 무한대로 갈수록 감소) 설계할 수 있다. 이때 더 작은 함수값을 달성하는 곳에서는 극값을 "달성"하지 않아 임계점이 추가로 생기지 않을 수 있다(즉, 하향 "계곡"을 따라 무한대로 빠지며 infimum은 더 작지만 minimum은 달성되지 않음). 따라서 "유일한 임계점이 국소 최소점"이라는 사실만으로 전역 최소를 결론내릴 수 없다.
  (반면, f**가 볼록**이면 임계점이 존재하는 경우 그 임계점은 전역 최소점이 된다.)

문제 9.2. 풀이

오차를 $e_k := |x_k - 1| = (0.5)^{2^k}$라 두면

$$e_{k+1} = (0.5)^{2^{k+1}} = \left((0.5)^{2^k}\right)^2 = (e_k)^2. \tag{8}$$

정의에 의해 $e_{k+1} = C\, e_k^2$ 꼴($C = 1$)이므로 $x_k \to 1$은 **Q-제곱(quadratic) 수렴**이다.

문제 9.3. 풀이 Rosenbrock류 함수 $f(x, y) = (1 - x)^2 + 5(y - x^2)^2$

(a) 그래디언트와 헤시안을 구하시오

$$\begin{aligned} &f_x = 2(x-1) - 20x\,(y - x^2), \qquad f_y = 10\,(y - x^2), \\ &f_{xx} = 2 - 20(y - x^2) + 40x^2 = 2 - 20y + 60x^2, \\ &f_{xy} = f_{yx} = -20x, \qquad f_{yy} = 10. \end{aligned} \tag{9}$$

(b) 임계점과 분류

$$f_y = 0 \;\Rightarrow\; y = x^2. \tag{10}$$

이를 f_x에 대입하면 $f_x = 2(x-1) = 0 \Rightarrow x = 1$, 따라서 $y = 1$.
임계점은 $(1, 1)$ 하나.

헤시안 at $(1, 1)$:

$$\begin{gathered} H(1,1) = \begin{pmatrix} 42 & -20 \\ -20 & 10 \end{pmatrix}, \\ \det = 42 \cdot 10 - (-20)^2 = 420 - 400 = 20 > 0,\ a_{11} = 42 > 0. \end{gathered} \tag{11}$$

양의 정부호 $\to (1, 1)$은 **엄격한 국소 최소점**.
게다가 $f = (1 - x)^2 + 5(y - x^2)^2 \geq 0$이며 $(1, 1)$에서 0을 달성하므로 **전역 최소점**이기도 하다.

문제 9.4. 풀이 $f(x, y) = 4y^3 + x^2 - 12y^2 - 36y + 2$

(a) 그래디언트와 헤시안

$$
\begin{aligned}
&f_x = 2x, \qquad f_y = 12y^2 - 24y - 36 = 12(y-3)(y+1), \\
&f_{xx} = 2, \qquad f_{xy} = f_{yx} = 0, \qquad f_{yy} = 24y - 24.
\end{aligned} \tag{12}
$$

(b) 임계점과 분류

임계점은 $f_x = 0 \Rightarrow x = 0$, $f_y = 0 \Rightarrow y \in \{3, -1\}$:
$(0,3)$, $(0,-1)$.

헤시안

- $(0,3)$: $H = \mathrm{diag}(2,\ 24 \cdot 3 - 24) = \mathrm{diag}(2, 48) \rightarrow$ **양의 정부호** $\rightarrow$ **국소 최소점**.
- $(0,-1)$: $H = \mathrm{diag}(2,\ 24 \cdot (-1) - 24) = \mathrm{diag}(2, -48) \rightarrow$ **부정부호(한 양, 한 음)** $\rightarrow$ **안장점 (saddle)**.

문제 9.5. 풀이
중심화된 입력에서

$$
\min_{\boldsymbol{\beta}} \ RSS_\lambda(\boldsymbol{\beta}) = (\boldsymbol{y} - \boldsymbol{X}\boldsymbol{\beta})^\top (\boldsymbol{y} - \boldsymbol{X}\boldsymbol{\beta}) + \lambda\, \boldsymbol{\beta}^\top \boldsymbol{\beta} \tag{13}
$$

목적함수를 $\boldsymbol{\beta}$에 대해 미분하여 0과 같게 둔다.

$$
\nabla_{\boldsymbol{\beta}} RSS_\lambda = -2\boldsymbol{X}^\top(\boldsymbol{y} - \boldsymbol{X}\boldsymbol{\beta}) + 2\lambda\boldsymbol{\beta} = 2(\boldsymbol{X}^\top\boldsymbol{X} + \lambda\mathbf{I})\boldsymbol{\beta} - 2\boldsymbol{X}^\top\boldsymbol{y}. \tag{14}
$$

정상조건을 풀면

$$
(\boldsymbol{X}^\top\boldsymbol{X} + \lambda\mathbf{I})\hat{\boldsymbol{\beta}}^{\text{ridge}} = \boldsymbol{X}^\top\boldsymbol{y} \quad \Rightarrow \quad \boxed{\hat{\boldsymbol{\beta}}^{\text{ridge}} = (\boldsymbol{X}^\top\boldsymbol{X} + \lambda\mathbf{I})^{-1}\boldsymbol{X}^\top\boldsymbol{y}}. \tag{15}
$$

헤시안은 $\nabla^2_{\boldsymbol{\beta}} RSS_\lambda = 2(\boldsymbol{X}^\top\boldsymbol{X} + \lambda\mathbf{I})$로 $\lambda > 0$이면 양의 정부호이므로 유일한 전역 최소해가 된다. (중심화로 절편은 0이 된다.)

문제 9.6. 풀이

가정: 독립 동일분포 $x_1, \ldots, x_n \sim \mathcal{N}(\mu, \nu)$ ($\nu = \sigma^2 > 0$).

(a) 로그가능도

$$
\begin{aligned}
f(\mu,\nu) = \ln p(\boldsymbol{x} \mid \mu, \nu) &= \sum_{i=1}^{n} \ln\Big[(2\pi\nu)^{-1/2} \exp\big(-\tfrac{1}{2\nu}(x_i - \mu)^2\big)\Big] \\
&= -\frac{n}{2}\ln(2\pi\nu) - \frac{1}{2\nu}\sum_{i=1}^{n}(x_i - \mu)^2.
\end{aligned} \tag{16}
$$

(b) 그래디언트와 임계점

오차제곱합 $S(\mu) := \sum_{i=1}^{n}(x_i - \mu)^2$.

- μ에 대해:

$$
\frac{\partial f}{\partial \mu} = -\frac{1}{2\nu} \cdot 2\sum_{i=1}^{n}(x_i - \mu)(-1) = \frac{1}{\nu}\sum_{i=1}^{n}(x_i - \mu). \tag{17}
$$

정상조건 $\partial f / \partial \mu = 0 \Rightarrow \sum(x_i - \mu) = 0 \Rightarrow \boxed{\mu^* = \bar{x} = \frac{1}{n}\sum x_i}$.

- ν에 대해:

$$\frac{\partial f}{\partial \nu} = -\frac{n}{2}\frac{1}{\nu} + \frac{1}{2}\Big(-\nu^{-2}\Big)\Big(-S(\mu)\Big) = -\frac{n}{2\nu} + \frac{S(\mu)}{2\nu^2}. \tag{18}$$

정상조건 $\partial f/\partial \nu = 0 \Rightarrow S(\mu) = n\nu \Rightarrow \boxed{\nu^* = \frac{1}{n}\sum_{i=1}^{n}(x_i-\mu)^2}$.

$\mu = \mu^*$를 대입하면 $\nu^* = \frac{1}{n}\sum(x_i-\bar{x})^2$ (MLE 표본분산).

(c) 헤시안과 전역 최대성

이계도함수:

$$\begin{aligned} \frac{\partial^2 f}{\partial \mu^2} = -\frac{n}{\nu}, \qquad \frac{\partial^2 f}{\partial \mu\,\partial \nu} = -\frac{1}{\nu^2}\sum_{i=1}^{n}(x_i-\mu), \\ \frac{\partial^2 f}{\partial \nu^2} = \frac{n}{2}\frac{1}{\nu^2} - \frac{S(\mu)}{\nu^3}. \end{aligned} \tag{19}$$

최적점 (μ^*, ν^*)에서 $\sum(x_i-\mu^*) = 0$이고 $S(\mu^*) = n\nu^*$이므로

$$\left.\frac{\partial^2 f}{\partial \mu^2}\right|_* = -\frac{n}{\nu^*} < 0, \quad \left.\frac{\partial^2 f}{\partial \mu\,\partial \nu}\right|_* = 0, \quad \left.\frac{\partial^2 f}{\partial \nu^2}\right|_* = \frac{n}{2}\frac{1}{\nu^{*2}} - \frac{n\nu^*}{\nu^{*3}} = -\frac{n}{2}\frac{1}{\nu^{*2}} < 0. \tag{20}$$

따라서 헤시안은 대각항이 음수, 비대각 0이어서 음의 정부호(국소 최대).

전역 최대성은 프로파일 로그가능도로 확인할 수 있다. ν를 최적화해

$$f(\mu, \nu^*(\mu)) = -\frac{n}{2}\left[1 + \ln(2\pi) + \ln\Big(\frac{S(\mu)}{n}\Big)\right]. \tag{21}$$

여기서 $S(\mu)$는 μ에 대한 볼록 이차식이고 $\mu = \bar{x}$에서 전역 최소가 된다. 즉 $f(\mu, \nu^*(\mu))$는 $\mu = \bar{x}$에서 전역 최대이며, 그때 $\nu = \nu^*$가 된다. 따라서

$$\boxed{\mu^* = \bar{x}, \qquad \nu^* = \frac{1}{n}\sum_{i=1}^{n}(x_i-\bar{x})^2} \tag{22}$$

가 **전역 최대** 로그가능도 추정량이다.

문제 9.7. 풀이

(a) 기대값의 과소 추정

재귀 전개(예: v_k)를 풀면

$$v_k = (1-\gamma_1)\sum_{t=1}^{k}\gamma_1^{k-t} g_t \quad (v_0 = 0). \tag{23}$$

기대값을 취하면

$$\mathbb{E}[v_k] = (1-\gamma_1)\sum_{t=1}^{k}\gamma_1^{k-t}\mathbb{E}[g_t] = (1-\gamma_1)\sum_{t=1}^{k}\gamma_1^{k-t} m = m(1-\gamma_1^k). \tag{24}$$

동일하게

$$\mathbb{E}[r_k] = (1-\gamma_2)\sum_{t=1}^{k}\gamma_2^{k-t}\mathbb{E}[g_t^2] = s_2(1-\gamma_2^k). \tag{25}$$

초기에는 γ_1^k, γ_2^k가 0이 아니므로 $1-\gamma_i^k < 1$. 따라서 $\mathbb{E}[v_k] = m(1-\gamma_1^k)$, $\mathbb{E}[r_k] = s_2(1-\gamma_2^k)$로 **과소 추정**된다.

(b) 편향 보정의 불편성

$$\begin{aligned}\mathbb{E}[\hat{v}_k] = \mathbb{E}\left[\frac{v_k}{1-\gamma_1^k}\right] = \frac{1}{1-\gamma_1^k}\,\mathbb{E}[v_k] = \frac{m(1-\gamma_1^k)}{1-\gamma_1^k} = m.\\ \mathbb{E}[\hat{r}_k] = \frac{1}{1-\gamma_2^k}\,\mathbb{E}[r_k] = \frac{s_2(1-\gamma_2^k)}{1-\gamma_2^k} = s_2.\end{aligned} \tag{26}$$

따라서 $\hat{v}_k,\ \hat{r}_k$는 각각 $m,\ s_2$의 **불편 추정량**이 된다(정상성 가정하).

(c) 귀납으로 v_k부터 보자. $k=1$에서 $v_1 = (1-\gamma_1)g_1$. 가정: $v_{k-1} = (1-\gamma_1)\sum_{t=1}^{k-1}\gamma_1^{k-1-t}g_t$. 그러면

$$\begin{aligned}v_k &= \gamma_1 v_{k-1} + (1-\gamma_1)g_k\\ &= \gamma_1(1-\gamma_1)\sum_{t=1}^{k-1}\gamma_1^{k-1-t}g_t + (1-\gamma_1)g_k\\ &= (1-\gamma_1)\sum_{t=1}^{k-1}\gamma_1^{k-t}g_t + (1-\gamma_1)\gamma_1^0 g_k\\ &= (1-\gamma_1)\sum_{t=1}^{k}\gamma_1^{k-t}g_t.\end{aligned} \tag{27}$$

r_k도 동일한 방식으로 증명된다.

계수들의 합은 등비수열 합:

$$(1-\gamma_1)\sum_{t=1}^{k}\gamma_1^{k-t} = 1-\gamma_1^k, \qquad (1-\gamma_2)\sum_{t=1}^{k}\gamma_2^{k-t} = 1-\gamma_2^k. \tag{28}$$

초기에는 $1-\gamma_i^k < 1$이므로 가중합이 **완전한 평균**(합=1)이 아니라 **부분 평균**이 되어, 값이 체계적으로 작게 나온다(과소 추정). 편향 보정은 정확히 이 "합이 1이 아님"을 역보정하는 연산이다.

문제 9.8. 풀이

(a) $k=1$에서의 값

주어진 $\gamma_1 = 0.9,\ \gamma_2 = 0.999,\ g_1 = 1.$

$$\begin{aligned}v_1 = (1-\gamma_1)g_1 = 0.1, \quad \hat{v}_1 = \frac{v_1}{1-\gamma_1} = 1.\\ r_1 = (1-\gamma_2)g_1^2 = 0.001, \quad \hat{r}_1 = \frac{r_1}{1-\gamma_2} = 1.\end{aligned} \tag{29}$$

(b) 스텝 크기 비율

$$\frac{\text{step}_{\text{uncorr}}}{\text{step}_{\text{corr}}} = \frac{\dfrac{v_k}{\sqrt{r_k}}}{\dfrac{\hat{v}_k}{\sqrt{\hat{r}_k}}} = \frac{v_k}{\hat{v}_k}\cdot\frac{\sqrt{\hat{r}_k}}{\sqrt{r_k}} = \frac{1-\gamma_1^k}{\sqrt{1-\gamma_2^k}}. \tag{30}$$

$k = 1$ 대입:

$$\frac{\text{step}_{\text{uncorr}}}{\text{step}_{\text{corr}}} = \frac{0.1}{\sqrt{0.001}} \approx \frac{0.1}{0.03162} \approx 3.162. \tag{31}$$

즉 **보정하지 않으면 초기 스텝이 보정보다 약 3.16배 커진다.**
설명: v의 과소 추정(분자↓, 계수 $1-\gamma_1$=0.1)보다 r의 과소 추정(분모의 $\sqrt{1-\gamma_2} = \sqrt{0.001}$)이 훨씬 더 커서, 전체 비율은 오히려 **증가**한다. 이것이 Adam에서 편향 보정이 **안정성**에 중요한 이유다.

보충: 보정이 업데이트에 미치는 일반적 영향

보정 없이 쓰는 업데이트 대비, 보정된 업데이트의 상대비는

$$\frac{\text{step}_{\text{uncorr}}}{\text{step}_{\text{corr}}} = \frac{1-\gamma_1^k}{\sqrt{1-\gamma_2^k}}. \tag{32}$$

Adam의 기본값 $(\gamma_1, \gamma_2) = (0.9, 0.999)$에서는 초기 k에서
$\sqrt{1-\gamma_2^k} \ll 1-\gamma_1^k$이므로 비율이 1보다 커지기 쉽다(업데이트가 과도하게 커짐).
따라서 **초반 폭주 방지**와 **스케일 안정성**을 위해 편향 보정은 필수적이다. 시간이 지남에 따라 $\gamma_i^k \to 1$로 가까워지며 비율은 1에 수렴한다.

10장 연습문제

문제 10.1. 다음 최적화 문제를 고려하자.

$$\begin{aligned} \text{Minimize} \quad & e^{-x} \\ \text{Subject to} \quad & x^2/y \leq 0 \end{aligned} \tag{1}$$

여기서 변수는 x, y이며, 정의역은 $D = \{(x, y) : y > 0\}$이다.

- (a) 이 문제가 볼록 최적화(convex optimization) 문제임을 확인하고, 최적값을 구하여라.
- (b) 이 문제의 라그랑주 쌍대 문제(Lagrange dual problem) 를 구하고, 쌍대 변수의 최적해 λ^*와 쌍대 최적값 d^*를 찾아라. 또한 최적 듀얼리티 갭(optimal duality gap) 을 구하고, Slater의 강듀얼리티 조건(Slater's condition) 이 이 문제에 대해 성립하는지 판단하라.

문제 10.2. 다음과 같은 원시(primal) 최적화 문제를 고려하자.

$$\begin{aligned} \text{Minimize} \quad & f(x_1, x_2) = (x_1 - 3/2)^2 + (x_2 - 1/2)^2 \\ \text{Subject to} \quad & |x_1| + |x_2| \leq 1 \end{aligned} \tag{2}$$

- (a) 함수 $f(x_1, x_2)$의 그래디언트(gradient) 와 헤시안(Hessian) 을 구하라. 이 함수가 볼록(convex)인지 설명하라.
- (b) 제약식 $|x_1| + |x_2| \leq 1$을 네 개의 부등식 형태로 표현하라. 즉, $g_i(x) \leq 0 \ (i = 1, 2, 3, 4)$의 형태로 나타내라.
- (c) 가능영역(feasible set) 과 목적함수의 등고선(level set) 을 함께 스케치하라.
- (d) 기하학적으로 최적점 (x_1^*, x_2^*)과 최적값 p^*를 구하라.

문제 10.3. 다음과 같은 엔트로피(Entropy) 최소화 문제(=엔트로피 최대화의 쌍대형) 를 고려하자.

$$\begin{aligned} \text{Minimize} \quad & \sum_{i=1}^{n} x_i \ln(x_i) \\ \text{Subject to} \quad & A\mathbf{x} \leq b, \\ & \mathbf{1}^T \mathbf{x} = 1, \quad \mathbf{x} \geq 0 \end{aligned} \tag{3}$$

여기서 A는 $m \times n$ 행렬이며, $m \ll n$이다. 이때 이 문제의 쌍대 문제(dual problem) 가 다음과 같이 표현될 수 있음을 보여라.

$$\begin{aligned} \text{Maximize} \quad & -\lambda^T b - \log(\sum_{i=1}^{n} e^{-a_i^T \lambda}) \\ \text{Subject to} \quad & \lambda \geq 0 \end{aligned} \tag{4}$$

문제 10.4. 다음과 같은 평균–분산 포트폴리오 최적화(mean–variance portfolio optimization) 문제를 고려하자.

$$
\begin{aligned}
\text{Minimize} \quad & \frac{1}{2}\boldsymbol{w}^T\Sigma\boldsymbol{w} \\
\text{Subject to} \quad & \boldsymbol{\mu}^T\boldsymbol{w} = \mu_p, \quad \mathbf{1}^T\boldsymbol{w} = 1
\end{aligned} \tag{5}
$$

여기서

- $\boldsymbol{w} \in \mathbb{R}^n$: 자산별 포트폴리오 비중(가중치), $\sum_i w_i = 1$.
- $\boldsymbol{\mu} \in \mathbb{R}^n$: 각 자산의 기대수익률 벡터.
- $\mu_p \in \mathbb{R}$: 목표(요구) 포트폴리오 기대수익률.
- $\mathbf{1} \in \mathbb{R}^n$: 모든 성분이 1인 벡터.
- $\Sigma \in \mathbb{R}^{n\times n}$: **수익률의 공분산 행렬(covariance matrix)**. 보통 $\Sigma \succeq 0$ (양의 준정부호), 실제 적용에서는 비특이성(역행렬 존재)을 위해 $\Sigma \succ 0$를 가정하는 경우가 많다.

또한

$$
A = \mathbf{1}^T\Sigma^{-1}\boldsymbol{\mu}, \quad B = \boldsymbol{\mu}^T\Sigma^{-1}\boldsymbol{\mu}, \quad C = \mathbf{1}^T\Sigma^{-1}\mathbf{1}, \quad D = BC - A^2. \tag{6}
$$

- (a) 위의 원시 문제(primal problem)가 볼록 최적화 문제(convex optimization problem) 임을 보여라.
- (b) KKT 조건을 사용하여 최적해가 다음과 같이 주어짐을 보여라:

$$
\boldsymbol{w}^* = -\Sigma^{-1}(\nu_1^*\boldsymbol{\mu} + \nu_2^*\mathbf{1}) = \frac{(C\mu_p - A)}{D}\Sigma^{-1}\boldsymbol{\mu} + \frac{(B - A\mu_p)}{D}\Sigma^{-1}\mathbf{1}. \tag{7}
$$

- (c) Wolfe 쌍대정리(Wolfe duality theorem) 를 사용하여 쌍대문제가 다음과 같이 표현됨을 보여라.

$$
\min_{\nu_1,\nu_2} \ \frac{1}{2}(B\nu_1^2 + C\nu_2^2 + 2A\nu_1\nu_2) + \mu_p\nu_1 + \nu_2 \tag{8}
$$

그리고, 이 쌍대문제의 최적해 (ν_1^*, ν_2^*)가 (b)에서 구한 $\boldsymbol{w}^*$와 동일한 해를 산출함을 보이라.

문제 10.5. 다음 물음에 답하시오.

- (a) 다음의 원시(primal) 최적화 문제 (P)에 대한 1차 필요 KKT 조건(first-order necessary KKT conditions) 을 서술하시오.

$$
\begin{aligned}
\text{maximize} \quad & f(x) \\
\text{subject to} \quad & g_i(x) = b_i, \ i = 1, \ldots, M \\
& h_j(x) \le c_j, \ j = 1, \ldots, K
\end{aligned} \tag{9}
$$

- (b) 만약 제약조건 중 일부가 변수의 비음수 제약(nonnegativity constraint) 형태, 즉 $x_n \ge 0$ 의 형태라고 하자.
  이때 x_n에 대한 1차 조건이 다음과 같이 변함을 보여라.

$$
\begin{aligned}
\frac{\partial f(\bar{x})}{\partial x_n} \le \sum_{i=1}^{M} \lambda_i \frac{\partial g_i(\bar{x})}{\partial x_n} + \sum_{j=1}^{K} \mu_j \frac{\partial h_j(\bar{x})}{\partial x_n}, \\
\mu_j \ge 0, \ j = 1, \ldots, K \quad \text{with equality if } \ \bar{x}_n > 0
\end{aligned} \tag{10}
$$

- (c) 다음의 효용 극대화 문제(Utility Maximization Problem; UMP) 를 고려하자.

$$
\begin{aligned}
\text{maximize}_{x\in\Re^L} \quad & u(x) \\
\text{subject to} \quad & p^T x \le w, \quad x \ge 0
\end{aligned} \tag{11}
$$

만약 x^*가 이 문제의 해라면, 어떤 $\lambda \geq 0$ 가 존재하여 모든 $l = 1, \ldots, L$에 대해 다음이 성립함을 보여라.

$$\frac{\partial u(x^*)}{\partial x_l} \leq \lambda p_l, \qquad \text{with equality if } \; x_l^* > 0 \tag{12}$$

- (d) 만약 최적해가 내부점(즉, $x_l^* > 0$ for all l)이라면, 재화 l과 k 사이의 한계대체율(MRS) 이 가격비율에 일치함을 보여라. 즉,

$$\frac{\partial u(x^*)/\partial x_l}{\partial u(x^*)/\partial x_k} = \frac{p_l}{p_k}. \tag{13}$$

문제 10.6. 다음 Trust-region subproblem 의 전역 최적해 p^*에 대한 필요충분조건을 구하시오.

$$\begin{aligned} \min_{p \in \mathbb{R}^n} \quad & m_k(p) = f_k + \nabla f_k^\top p + \tfrac{1}{2} p^\top B_k p, \\ \text{제약조건} \quad & \|p\|_2 \leq \Delta_k, \end{aligned} \tag{14}$$

여기서 $\Delta_k > 0$는 trust-region 반지름이다.

문제 10.7. 다음 최적화 문제를 고려하자.

$$\begin{aligned} \min_{x_1, x_2} \quad & f(x_1, x_2) = (x_1 - 1)^2 + x_2^2, \\ \text{subject to} \quad & -4x_1 + x_2^2 \geq 0. \end{aligned} \tag{15}$$

(a) 가능한 영역(feasible set)과 목적함수의 등고선을 스케치하라.
(b) KKT 조건을 사용하여 최적해 (x_1^*, x_2^*), 라그랑주 승수 λ^*, 최적값 p^*을 구하라.

문제 10.8. (Fisher의 문제: Rayleigh 몫 최대화)

두 개의 대칭 행렬 $C_A, C_W \in \mathbb{R}^{n \times n}$와 벡터 $\boldsymbol{k} \in \mathbb{R}^n$가 있을 때, Fisher의 판별 문제는 다음의 Rayleigh 몫을 최대화하는 것이다.

$$\max_{\boldsymbol{k} \neq 0} \quad R(\boldsymbol{k}) = \frac{\boldsymbol{k}^T \mathbf{C}_A \boldsymbol{k}}{\boldsymbol{k}^T \mathbf{C}_W \boldsymbol{k}}. \tag{16}$$

이는 스케일 불변이므로, 동치인 다음의 제약 최적화 문제로 쓸 수 있다:

$$\max_{k} \quad \boldsymbol{k}^T \mathbf{C}_A \boldsymbol{k} \qquad \text{s.t.} \quad \boldsymbol{k}^T \mathbf{C}_W \boldsymbol{k} = 1. \tag{17}$$

이때 최적의 $\boldsymbol{k}$를 구하라.

10장 연습문제 해답

문제 10.1. 풀이

$$\min_{x,y}\ e^{-x} \quad \text{s.t.} \quad \frac{x^2}{y} \le 0, \quad D = \{(x,y) : y > 0\} \tag{18}$$

(a) 볼록성 확인 및 최적값

목적함수 e^{-x} 는 x에 대해 2계도함수 $\frac{d^2}{dx^2}e^{-x} = e^{-x} > 0$ 이므로 볼록.

제약함수 $g(x,y) = \frac{x^2}{y}$ 는 $y > 0$에서 (x^2)의 퍼스펙티브(perspective) 형태이므로 볼록.

> 어떤 함수 $f : \mathbb{R}^n \to \mathbb{R}$ 가 볼록이면, 그 **퍼스펙티브(perspective)**
>
> $$\phi(x,t) = t\,f(x/t) \quad (t > 0) \tag{19}$$
>
> 는 (x,t)에 대해 볼록이다. 여기서 $f(z) = z^2$ 는 잘 알려진 볼록 함수이다.
>
> 그러면
>
> $$\phi(x,y) = y\,f(x/y) = y\,(x/y)^2 = \frac{x^2}{y}, \qquad (y > 0) \tag{20}$$
>
> 가 곧 f의 퍼스펙티브이므로 (x,y)에 대해 볼록이다.

따라서 볼록최적화 문제.

또한 $y > 0$일 때 $\frac{x^2}{y} \ge 0$. 제약 $\frac{x^2}{y} \le 0$ 를 만족하려면 반드시 $\frac{x^2}{y} = 0 \Rightarrow x = 0$ 이어야 하며, $y > 0$는 자유.
따라서 가능해집합은 $\{(0,y) : y > 0\}$. 이 집합에서 목적함수는 $e^{-x} = e^0 = 1$.
최적값 $p^* = 1$, 최적해는 $x^* = 0$ ($y > 0$ 임의).

(b) 라그랑주 쌍대와 쌍대 최적값, 갭, Slater

라그랑지안(불평등 제약 승수 $\lambda \ge 0$):

$$L(x,y,\lambda) = e^{-x} + \lambda\,\frac{x^2}{y}. \tag{21}$$

쌍대함수 $g(\lambda) = \inf_{y>0} \inf_{x\in\mathbb{R}} L$.

- 고정 x에서 $\inf_{y>0} \lambda x^2/y = 0$ ($y \to \infty$ 로 보낼 수 있음, $\lambda \ge 0$).
  따라서 $g(\lambda) = \inf_x e^{-x} = 0$ ($x \to +\infty$ 이면 $e^{-x} \to 0$; 하한 0, 달성 안 됨).
- 쌍대문제: $\max_{\lambda\ge 0} g(\lambda) = \max_{\lambda \ge 0} 0$.

  쌍대 최적값 $d^* = 0$, 최적 승수는 λ^* 임의의 $\lambda \ge 0$.

듀얼리티 갭 $p^* - d^* = 1 - 0 = 1$ (양수).
Slater 조건: $\exists (x,y)$ s.t. $g(x,y) < 0$ (엄격하게 만족) 필요. 그러나 $y > 0$에서 $\frac{x^2}{y} \ge 0$ 이므로 엄격가능점이 존재하지 않음 → Slater 불만족, 그 결과 강듀얼리티 실패(양의 갭 발생).

문제 10.2. 풀이

$$\min_{x_1,x_2} f(x_1,x_2) = \left(x_1 - \tfrac{3}{2}\right)^2 + \left(x_2 - \tfrac{1}{2}\right)^2 \quad \text{s.t.} \quad |x_1| + |x_2| \le 1. \tag{22}$$

(a) 그라디언트와 헤시안, 볼록성

$$\nabla f(x) = \begin{bmatrix} 2(x_1 - \frac{3}{2}) \\ 2(x_2 - \frac{1}{2}) \end{bmatrix}, \qquad \nabla^2 f(x) = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} = 2I_2 \succ 0. \tag{23}$$

헤시안이 항등행렬의 양의배수이므로 강볼록 함수. 따라서 전역 유일해 존재.

(b) 제약을 네 개의 부등식으로

$|x_1| + |x_2| \le 1$ 은 다음 네 직선의 교집합으로 표현:

$$\begin{cases} g_1(x) = x_1 + x_2 - 1 \le 0, \\ g_2(x) = x_1 - x_2 - 1 \le 0, \\ g_3(x) = -x_1 + x_2 - 1 \le 0, \\ g_4(x) = -x_1 - x_2 - 1 \le 0. \end{cases} \tag{24}$$

(정확히는 L1-볼 $\{x : |x_1| + |x_2| \le 1\}$ = 위 네 반평면의 교집합.)

(c) 가능집합/레벨셋 스케치

가능집합은 원점 중심의 마름모(꼭짓점 $(\pm 1, 0), (0, \pm 1)$).
목적함수 레벨셋은 중심 $(1.5, 0.5)$ 의 동심원(유클리드 구). 최소점은 이 동심원이 마름모와 처음 접하는 점.

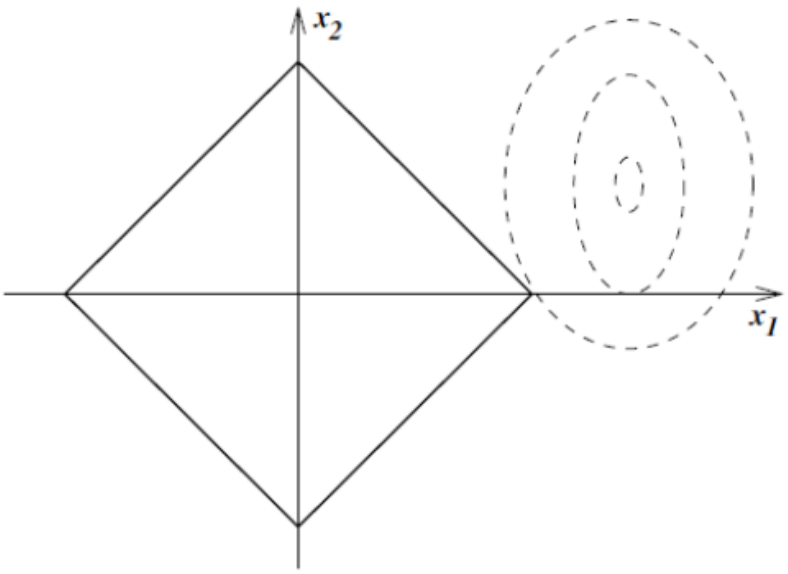

그림 문제 10.2.(c) 풀이

(d) 최적해와 최적값(기하적으로)

무제약 최소점은 $(1.5, 0.5)$ 이지만 가능영역 밖. L1-볼로의 유클리드 사영으로 해를 얻음(소프트-스레숄딩과 동일).

양의 사분면에서 활성 제약은 $x_1 + x_2 = 1$.
$(1.5, 0.5)$ 를 $x_1 + x_2 = 1$ 에 정사영하면

$$\tau \ge 0 \text{ s.t. } (1.5 - \tau) + (0.5 - \tau) = 1 \;\Rightarrow\; \tau = 0.5, \tag{25}$$

$\Rightarrow (x_1^*, x_2^*) = (1.0, 0.0)$.

최적값:

$$p^* = (1-1.5)^2 + (0-0.5)^2 = \tfrac{1}{4} + \tfrac{1}{4} = \boxed{0.5}. \tag{26}$$

문제 10.3. 풀이 (엔트로피 최소화의 쌍대)

$$\min_{x\in\mathbb{R}^n} \sum_{i=1}^n x_i \ln x_i \quad \text{s.t.} \quad Ax \le b,\ \mathbf{1}^\top x = 1,\ x \ge 0, \tag{27}$$

(여기서 $A = [a_1, \ldots, a_n]$의 열벡터 표기를 사용하면 각 항에 a_i가 대응.)

라그랑주 승수 $\lambda \ge 0$ ($Ax \le b$용), 스칼라 ν ($\mathbf{1}^\top x = 1$용). ($x \ge 0$는 영역에 흡수 가능—최적점에서 $x_i > 0$ 이므로 카라시–쿤–터커의 보완조건로 $s = 0$ 이 됨.)

라그랑지안:

$$\begin{aligned} L(x,\lambda,\nu) &= \sum_{i=1}^n x_i \ln x_i + \lambda^\top (Ax - b) + \nu(\mathbf{1}^\top x - 1) \\ &= -\lambda^\top b - \nu + \sum_{i=1}^n \left[x_i \ln x_i + (a_i^\top \lambda + \nu)\, x_i\right]. \end{aligned} \tag{28}$$

쌍대함수는 $x \ge 0,\ \mathbf{1}^\top x = 1$ 하의 최소값:

$$\begin{aligned} g(\lambda,\nu) &= -\lambda^\top b - \nu + \min_{\substack{x\ge 0 \\ \mathbf{1}^\top x = 1}} \sum_{i=1}^n \left[x_i \ln x_i + (a_i^\top \lambda + \nu)\, x_i\right] \\ &= -\lambda^\top b - \nu + \min_{x\in\Delta} \Big[\sum_{i=1}^n x_i \ln x_i + \sum_{i=1}^n x_i (a_i^\top \lambda + \nu)\Big], \end{aligned} \tag{29}$$

여기서 $\Delta = \{x \ge 0,\ \mathbf{1}^\top x = 1\}$ (단체).

표준 결과(또는 라그랑주-최적화로 직접 계산)로

$$\min_{x\in\Delta}\ \sum_i x_i \ln x_i + \sum_i c_i x_i = -\log\Big(\sum_{i=1}^n e^{-c_i}\Big), \quad (c_i = a_i^\top \lambda + \nu). \tag{30}$$

따라서

$$g(\lambda,\nu) = -\lambda^\top b - \nu - \log\Big(\sum_{i=1}^n e^{-(a_i^\top \lambda + \nu)}\Big). \tag{31}$$

ν에 대해 최적화하면

$$-\nu - \log\left(e^{-\nu} \sum_{i=1}^n e^{-a_i^\top \lambda}\right) = -\nu + \nu - \log\left(\sum_{i=1}^n e^{-a_i^\top \lambda}\right) = -\log\left(\sum_{i=1}^n e^{-a_i^\top \lambda}\right), \tag{32}$$

즉 ν는 소거되고

$$\boxed{\max_{\lambda\ge 0} \quad -\lambda^\top b - \log\left(\sum_{i=1}^n e^{-a_i^\top \lambda}\right)} \tag{33}$$

이 쌍대문제가 된다(요구식과 동일).

문제 10.4. 풀이 (평균–분산 포트폴리오)

$$\min_{w} \ \tfrac{1}{2} w^{\top} \Sigma w \quad \text{s.t.} \quad \mu^{\top} w = \mu_p, \ \mathbf{1}^{\top} w = 1, \tag{34}$$

$A = \mathbf{1}^{\top}\Sigma^{-1}\mu, \ B = \mu^{\top}\Sigma^{-1}\mu, \ C = \mathbf{1}^{\top}\Sigma^{-1}\mathbf{1}, \ D = BC - A^2.$

(a) 볼록성

$\Sigma \succeq 0$ (대개 $\succ 0$)이면 $w \mapsto \frac{1}{2} w^{\top}\Sigma w$ 은 볼록(엄밀히는 $\Sigma \succ 0$이면 강볼록). 제약은 선형 등식. 따라서 볼록최적화 문제.

(b) KKT로 w^* 도출

1. 라그랑지안: 등식 제약의 승수를 $\nu_1, \ \nu_2 \in \mathbb{R}$라 하면,

$$L(\boldsymbol{w}, \nu_1, \nu_2) = \frac{1}{2}\, \boldsymbol{w}^{\top}\Sigma\boldsymbol{w} + \nu_1(\boldsymbol{\mu}^{\top}\boldsymbol{w} - \mu_p) + \nu_2(\mathbf{1}^{\top}\boldsymbol{w} - 1). \tag{35}$$

2. 정지조건(Stationarity)

$$\nabla_{\boldsymbol{w}} L = \Sigma\boldsymbol{w} + \nu_1\boldsymbol{\mu} + \nu_2\mathbf{1} = \mathbf{0} \quad \Rightarrow \quad \boldsymbol{w}^* = -\Sigma^{-1}(\nu_1^*\boldsymbol{\mu} + \nu_2^*\mathbf{1}). \tag{36}$$

3. 원시 제약 대입

$$\begin{cases} \boldsymbol{\mu}^{\top}\boldsymbol{w}^* = \mu_p, \\ \mathbf{1}^{\top}\boldsymbol{w}^* = 1, \end{cases} \quad \Rightarrow \quad \begin{cases} -(\nu_1^* B + \nu_2^* A) = \mu_p, \\ -(\nu_1^* A + \nu_2^* C) = 1. \end{cases} \tag{37}$$

즉,

$$\begin{bmatrix} B & A \\ A & C \end{bmatrix} \begin{bmatrix} \nu_1^* \\ \nu_2^* \end{bmatrix} = -\begin{bmatrix} \mu_p \\ 1 \end{bmatrix}. \tag{38}$$

이 2×2 선형계의 해는(행렬식 $D = BC - A^2$):

$$\nu_1^* = \frac{A - C\mu_p}{D}, \qquad \nu_2^* = \frac{A\mu_p - B}{D}. \tag{39}$$

4. 최적 가중치

이를 정지식에 대입:

$$\boxed{\boldsymbol{w}^* = -\Sigma^{-1}(\nu_1^*\boldsymbol{\mu} + \nu_2^*\mathbf{1}) = \frac{(C\mu_p - A)}{D}\,\Sigma^{-1}\boldsymbol{\mu} + \frac{(B - A\mu_p)}{D}\,\Sigma^{-1}\mathbf{1}.} \tag{40}$$

5. $D > 0$ 임을 왜 기대할 수 있나?

$\langle x, y\rangle_{\Sigma^{-1}} := x^{\top}\Sigma^{-1}y$ 를 내적으로 보면 $B = \langle \mu, \mu\rangle, \ C = \langle 1, 1\rangle, \ A = \langle 1, \mu\rangle.$
코시–슈바르츠로 $A^2 \le BC$. 만약 μ가 $\mathbf{1}$과 Σ^{-1}-의미에서 완전 공선이면 $A^2 = BC$가 되며 $D = 0$ (퇴화). 일반적으로 서로 독립 정보라면 $D > 0$.

> 해석: $D > 0$이면 두 등식 제약이 Σ^{-1} 공간에서 "충분히 독립"이라 유일 최적해가 성립.

(c) Wolfe 쌍대와 일치성

1. 쌍대함수 계산(완전제곱): 라그랑지안에서 $\boldsymbol{w}$에 대해 $\inf$를 취하면

$$\inf_{\boldsymbol{w}} \left(\tfrac{1}{2}\boldsymbol{w}^{\top}\Sigma\boldsymbol{w} + \nu_1\mu^{\top}\boldsymbol{w} + \nu_2\mathbf{1}^{\top}\boldsymbol{w} \right) = -\tfrac{1}{2}(\nu_1\mu + \nu_2\mathbf{1})^{\top}\Sigma^{-1}(\nu_1\mu + \nu_2\mathbf{1}). \tag{41}$$

따라서 쌍대함수는

$$g(\nu_1, \nu_2) = -\tfrac{1}{2}(\nu_1\mu + \nu_2\mathbf{1})^{\top}\Sigma^{-1}(\nu_1\mu + \nu_2\mathbf{1}) - \nu_1\mu_p - \nu_2. \tag{42}$$

쌍대문제는 이를 **최대화**. 등가로 부호를 바꾸어 **최소화**로 쓰면

$$\boxed{\min_{\nu_1,\nu_2} \frac{1}{2}\big(B\nu_1^2 + C\nu_2^2 + 2A\nu_1\nu_2\big) + \mu_p\nu_1 + \nu_2.} \tag{43}$$

(여기서 $B = \mu^\top\Sigma^{-1}\mu,\ C = \mathbf{1}^\top\Sigma^{-1}\mathbf{1},\ A = \mathbf{1}^\top\Sigma^{-1}\mu$.)

2. 쌍대 최적조건과 (b)와의 일치

쌍대 목적을 (ν_1, ν_2)로 미분하여 0으로 두면

$$\begin{cases} B\nu_1 + A\nu_2 + \mu_p = 0, \\ A\nu_1 + C\nu_2 + 1 = 0, \end{cases} \tag{44}$$

이 바로 (b)에서 풀었던 동일한 2×2 선형계입니다. 따라서

$$(\nu_1^*, \nu_2^*) = \Big(\frac{A - C\mu_p}{D},\ \frac{A\mu_p - B}{D}\Big), \tag{45}$$

이를 정지식 $\boldsymbol{w}^* = -\Sigma^{-1}(\nu_1^*\mu + \nu_2^*\mathbf{1})$에 대입하면 (b)의 $\boldsymbol{w}^*$와 **동일**함을 확인한다.

참조: 효율적 프론티어와 분산 공식

최적해 $\boldsymbol{w}^*$의 분산(최소화된 목적값의 2배)은

$$\sigma^2(\mu_p) = \boldsymbol{w}^{*\top}\Sigma\boldsymbol{w}^* = \frac{C\mu_p^2 - 2A\mu_p + B}{D}. \tag{46}$$

이는 (μ_p, σ^2)가 포물선(효율적 프론티어)을 이룬다는 고전 결과를 준다.

- μ_p를 변화시키면 $\boldsymbol{w}^*(\mu_p)$가 선형 결합 형태로 움직이며,
- $\Sigma^{-1}\mu$ 축("탄젠시 포트폴리오" 성분)과 $\Sigma^{-1}1$ 축("최소분산 방향" 성분)의 조합으로 표현된다.

문제 10.5. 풀이

(a) KKT 조건 (최대화형)

라그랑지안 정의:

$$L(x, \lambda, \mu) = f(x) + \sum_{i=1}^{M} \lambda_i(b_i - g_i(x)) + \sum_{j=1}^{K} \mu_j(c_j - h_j(x)), \tag{47}$$

여기서 $\mu_j \geq 0$.

KKT 1차 필요조건:

1. **Stationarity (정지 조건)**

$$\nabla f(x^*) = \sum_{i=1}^{M} \lambda_i \nabla g_i(x^*) + \sum_{j=1}^{K} \mu_j \nabla h_j(x^*). \tag{48}$$

2. **Primal feasibility (원시 가능성)**

$$g_i(x^*) = b_i, \quad i = 1, \ldots, M, \quad h_j(x^*) \leq c_j, \quad j = 1, \ldots, K. \tag{49}$$

3. **Dual feasibility (쌍대 가능성)**

$$\mu_j \geq 0, \quad j = 1, \ldots, K. \tag{50}$$

4. **Complementary slackness (상보성 조건)**

$$\mu_j \left(c_j - h_j(x^*)\right) = 0, \quad j = 1, \ldots, K. \tag{51}$$

(b) 비음수 제약 $x_n \geq 0$ 추가 시

이 제약을 불평등 형태로 쓰면 $-x_n \leq 0$ 또는 $x_n \geq 0 \Rightarrow -x_n \leq 0$.

이에 대한 승수를 $\nu_n \geq 0$라 하면, KKT의 stationarity 조건의 x_n 성분은

$$\frac{\partial f(\bar{x})}{\partial x_n} = \sum_i \lambda_i \frac{\partial g_i(\bar{x})}{\partial x_n} + \sum_j \mu_j \frac{\partial h_j(\bar{x})}{\partial x_n} - \nu_n. \tag{52}$$

여기서 $\nu_n \geq 0$ 이고, 상보성 조건 $\nu_n \, \bar{x}_n = 0$.

즉,

- 만약 $\bar{x}_n > 0 \Rightarrow \nu_n = 0$: 등호 관계
- 만약 $\bar{x}_n = 0 \Rightarrow \nu_n \geq 0$: 불등호 관계

따라서

$$\frac{\partial f(\bar{x})}{\partial x_n} \leq \sum_i \lambda_i \frac{\partial g_i(\bar{x})}{\partial x_n} + \sum_j \mu_j \frac{\partial h_j(\bar{x})}{\partial x_n}, \tag{53}$$

등호는 $\bar{x}_n > 0$일 때만 성립.

(c) 효용극대화 문제의 KKT

라그랑지안:

$$L(x, \lambda, \nu) = u(x) + \lambda(w - p^T x) + \sum_{l=1}^{L} \nu_l x_l, \qquad \lambda \geq 0, \ \nu_l \geq 0. \tag{54}$$

정지조건:

$$\frac{\partial L}{\partial x_l} = \frac{\partial u(x)}{\partial x_l} - \lambda p_l + \nu_l = 0 \quad \Rightarrow \quad \frac{\partial u(x^*)}{\partial x_l} = \lambda p_l - \nu_l. \tag{55}$$

$\nu_l \geq 0, \ x_l^* \geq 0, \ \nu_l x_l^* = 0.$

따라서

- $x_l^* > 0$이면 $\nu_l = 0 \Rightarrow \frac{\partial u(x^*)}{\partial x_l} = \lambda p_l$.
- $x_l^* = 0$이면 $\nu_l \geq 0 \Rightarrow \frac{\partial u(x^*)}{\partial x_l} \leq \lambda p_l$.

즉,

$$\boxed{\frac{\partial u(x^*)}{\partial x_l} \leq \lambda p_l, \quad \text{등호는 } x_l^* > 0\text{일 때 성립.}} \tag{56}$$

(d) 내부 최적점일 때 $x_l^* > 0 \ \forall l$

모든 l에 대해 $\frac{\partial u(x^*)}{\partial x_l} = \lambda p_l$. 두 재화 l, k의 비율을 취하면

$$\frac{\partial u(x^*)/\partial x_l}{\partial u(x^*)/\partial x_k} = \frac{\lambda p_l}{\lambda p_k} = \frac{p_l}{p_k}. \tag{57}$$

즉, **한계대체율(MRS)** = **가격비율**, 경제학적으로 "소비자는 예산 제약 하에서 효용을 극대화할 때 한계대체율이 가격비율과 일치한다"는 결과를 다시 얻습니다.

문제 10.6. 풀이

1. 라그랑주 함수 (Lagrangian) 설정

이 문제는 등식 제약이 아닌 부등식 제약 조건($\|p\|_2^2 \le \Delta_k^2$)을 포함하고 있습니다. 라그랑주 승수 λ를 도입하여 라그랑주 함수를 정의합니다. (미분의 편의를 위해 제곱 형태를 사용합니다.)

$$L(p, \lambda) = \nabla f_k^\top p + \tfrac{1}{2} p^\top B_k p + \tfrac{\lambda}{2}(p^\top p - \Delta_k^2)$$

(상수항 f_k는 최적해 위치에 영향을 주지 않으므로 생략 가능합니다.)

2. KKT 조건 (Karush-Kuhn-Tucker Conditions)

최적해의 후보가 되기 위한 1차 필요조건(KKT 조건)을 구합니다.

- Stationarity: $\nabla_p L(p, \lambda) = 0$

  $$\nabla f_k + B_k p + \lambda p = 0 \quad \Rightarrow \quad (B_k + \lambda I)p = -\nabla f_k$$

  이 식은 위 정리의 조건 1이 됩니다.
- Feasibility & Dual Feasibility:

  $$\|p\|_2 \le \Delta_k, \quad \lambda \ge 0$$

  이 식은 위 정리의 조건 3과 λ의 조건이 됩니다.
- Complementary Slackness:

  $$\lambda(\|p\|_2^2 - \Delta_k^2) = 0 \quad \Leftrightarrow \quad \lambda(\Delta_k - \|p\|_2) = 0$$

  이 식은 위 정리의 조건 4가 됩니다. 이는 $\lambda > 0$이면 반드시 해가 경계에 있어야 하고($\|p^*\| = \Delta_k$), 해가 내부에 있다면($\|p^*\| < \Delta_k$) 반드시 $\lambda = 0$이어야 함을 의미합니다.

3. 2차 조건 (Second-Order Condition) - *핵심 포인트*

일반적인 KKT 조건은 극소, 극대, 안장점(Saddle point)을 구분하지 못합니다. 하지만 TRS에서는 다음 조건이 추가됨으로써 **전역 최소(Global Minimum)**임이 보장됩니다.

$$(B_k + \lambda I) \succeq 0$$

왜 이 조건이 필요한가요?

- 목적 함수 $m_k(p)$는 헤시안 B_k를 가집니다. B_k가 양의 정부호(Positive Definite)가 아니라면 함수는 아래로 볼록하지 않을 수 있습니다.
- 하지만 라그랑주 함수 L의 p에 대한 헤시안은 $\nabla_{pp}^2 L = B_k + \lambda I$ 입니다.
- 이 행렬이 양의 준정부호(PSD)여야만, 해당 지점이 (지역적) 최소해(Minimizer)가 될 수 있습니다.
- Trust-Region 문제의 특수한 구조 덕분에, 이 조건은 지역 최적해뿐만 아니라 **전역 최적해**임을 보장하는 필요충분조건이 됩니다.

요약

따라서 구하는 해 p^*는 단순히 $m_k(p)$를 미분해서 0이 되는 점이 아니라, **행렬 $(B_k + \lambda I)$가 양의 준정부호가 되도록 하는 λ에 의해 수정된 선형 시스템**을 만족하는 해여야 합니다.

이 조건을 만족하는 해는 크게 두 가지 경우로 나뉩니다:

1. **내부 해 (Interior Solution):** B_k가 양의 정부호이고, 뉴턴 스텝(Unconstrained minimizer)이 신뢰 영역 안에 있을 때 ($\lambda = 0$). 즉, $\|p^*\| < \Delta_k \Rightarrow \lambda = 0. \Rightarrow B_k p^* = -\nabla f_k$ (뉴턴 스텝).
2. **경계 해 (Boundary Solution):** B_k가 양의 정부호가 아니거나, 뉴턴 스텝이 신뢰 영역 밖에 있을 때 ($\lambda > 0$, $\|p^*\| = \Delta_k$). 즉, $\|p^*\| = \Delta_k,\ \lambda > 0. \Rightarrow p^* = -(B_k + \lambda I)^{-1}\nabla f_k,\ \lambda$는 $\|p^*\| = \Delta_k$을 만족시키도록 선택.

(필요충분조건 정리)

$$\boxed{\begin{cases} (B_k + \lambda I)p^* = -\nabla f_k, \\ \|p^*\| \le \Delta_k,\ \lambda \ge 0 \\ \lambda(\|p^*\| - \Delta_k) = 0, \\ B_k + \lambda I \succeq 0. \end{cases}} \tag{58}$$

이 네 조건이 **trust-region subproblem의 필요충분조건**이다.

문제 10.7. 풀이

(a) 가능영역 설명

제약식: $-4x_1 + x_2^2 \ge 0 \Rightarrow x_1 \le \frac{x_2^2}{4}$.

즉, 포물선 $x_1 = x_2^2/4$ **왼쪽 영역**이 가능집합.
목적함수는 중심이 $(1, 0)$인 원형 등고선 $(x_1 - 1)^2 + x_2^2 = \text{const.}$ → (1,0)은 제약 밖(오른쪽)이고, 최적해는 포물선 경계 위 접점.

(b) KKT 전개

1. 제약을 표준형 $g(x) \le 0$으로 쓰면
   $g(x_1, x_2) = -4x_1 + x_2^2 \ge 0 \Leftrightarrow -g(x) \le 0.$
   즉, $h(x) = 4x_1 - x_2^2 \le 0.$
2. 라그랑지안

$$L(x_1, x_2, \lambda) = (x_1 - 1)^2 + x_2^2 + \lambda(4x_1 - x_2^2), \quad \lambda \ge 0. \tag{59}$$

3. 정지조건 (Stationarity)

$$\frac{\partial L}{\partial x_1} = 2(x_1 - 1) + 4\lambda = 0, \quad \frac{\partial L}{\partial x_2} = 2x_2 - 2\lambda x_2 = 0. \tag{60}$$

   두 번째 식에서 $\Rightarrow x_2(1 - \lambda) = 0.$

경우 1: $x_2 = 0$

그럼 제약식 $4x_1 - x_2^2 = 4x_1 \le 0 \Rightarrow x_1 \le 0.$

Stationarity 첫 식에서

$$2(x_1 - 1) + 4\lambda = 0 \Rightarrow x_1 = 1 - 2\lambda. \tag{61}$$

가능하려면 $x_1 \le 0 \Rightarrow 1 - 2\lambda \le 0 \Rightarrow \lambda \ge 0.5$. 보완조건 $\lambda(4x_1 - x_2^2) = 0$은 경계면(활성)일 때 $4x_1 - x_2^2 = 0$이어야 하므로 $x_1 = 0$, $\lambda = 0.5$.

따라서 $(x_1^*, x_2^*, \lambda^*) = (0, 0, 0.5)$. 목적값: $f(0,0) = (0-1)^2 + 0 = 1$.

경우 2: $\lambda = 1$

그럼 첫 식 $2(x_1 - 1) + 4(1) = 0 \Rightarrow x_1 - 1 = -2 \Rightarrow x_1 = -1$. 제약식 $4x_1 - x_2^2 = 4(-1) - x_2^2 \le 0$ 항상 만족하므로 가능.
하지만 보완조건 확인:
$\lambda(4x_1 - x_2^2) = 1(4(-1) - x_2^2) = -4 - x_2^2 \ne 0$. 불만족. → 폐기.

결론

$$\boxed{x_1^* = 0, \quad x_2^* = 0, \quad \lambda^* = 0.5, \quad p^* = 1.} \tag{62}$$

최적해는 제약 경계 위(활성), 목적함수 등고선이 포물선과 접하는 점이다.

문제 10.8. 풀이

1. 라그랑지안과 KKT(정지조건)

라그랑지안

$$\mathcal{L}(k, \lambda) = k^\top C_A k - \lambda\,(k^\top C_W k - 1). \tag{63}$$

정지조건(일차조건) $\nabla_k \mathcal{L} = 0$을 주면

$$2C_A k - 2\lambda\, C_W k = 0 \quad \Longleftrightarrow \quad C_A k = \lambda\, C_W k. \tag{64}$$

즉, **일반화 고유값 문제(generalized eigenvalue problem)**:

$$(C_A,\, C_W)\text{에 대해 } C_A k = \lambda C_W k, \quad \text{추가로 } k^\top C_W k = 1 \text{ (정규화)}. \tag{65}$$

2. 최적해의 형태

- $C_W \succ 0$ (대칭 양의정정부호)라고 가정하면, 위 문제는 표준적인 일반화 고유값 문제이며 **최적의** k^* 는

$$C_A k^* = \lambda_{\max}\, C_W k^*, \qquad (k^*)^\top C_W k^* = 1 \tag{66}$$

를 만족하는 **가장 큰 일반화 고유값** $\lambda_{\max}$ 에 대응하는 **일반화 고유벡터**이다.

- 이때 목적함수의 최댓값은

$$(k^*)^\top C_A k^* = \lambda_{\max}. \tag{67}$$

(제약 $k^\top C_W k = 1$ 때문에 Rayleigh 몫 값이 그대로 λ가 됨.)

3. 표준 고유값 문제로의 환원(계산 팁)

- $C_W \succ 0$이면 C_W^{-1} 또는 $C_W^{-1/2}$로 **화이트닝(whitening)** 하여

$$C_A k = \lambda C_W k \iff C_W^{-1/2} C_A C_W^{-1/2}\, y = \lambda y, \quad (y = C_W^{1/2} k) \tag{68}$$

의 **대칭 표준 고유값 문제**로 바뀐다. 가장 큰 고유값 $\lambda_{\max}$에 대응하는 고유벡터 $y_{\max}$를 구한 뒤,

$$k^* = C_W^{-1/2} y_{\max}, \qquad \text{그리고 } (k^*)^\top C_W k^* = 1 \text{ 로 정규화}. \tag{69}$$

- 또는 비대칭일 수 있는 $C_W^{-1}C_A$의 **우고유벡터**를 구해도 되지만, 수치안정성과 대칭성 확보를 위해 $C_W^{-1/2}C_AC_W^{-1/2}$를 쓰는 방식이 표준이다.