5장 특이값 분해(Singular Value Decomposition, SVD)

written by Han Suebin

5.1 고유치(Eigenvalues)

5.1.1 고유치와 고유벡터

고유치(eigenvalue)와 고유벡터(eigenvector)

행렬 A를 벡터 $\mathbf{v}$에 곱하면 일반적으로 벡터의 방향과 크기가 모두 변합니다. 하지만 고유벡터는 행렬을 곱해도 방향이 전혀 변하지 않고 고유치만 변화합니다.

$$\text{대상행렬} : A = \begin{bmatrix} 4 & 1 \\ 2 & 3 \end{bmatrix} \tag{1}$$

분석 항목	수식 및 계산 과정	수치 결과	전문적 해석
특성 방정식	$\det(A - \lambda I) = 0$	$\lambda^2 - 7\lambda + 10 = 0$	고유값을 찾기 위한 다항식
고유값 (λ)	$(\lambda - 5)(\lambda - 2) = 0$	$\lambda_1 = 5, \lambda_2 = 2$	공간의 주축별 변환 배율
제1 고유벡터	$(A - 5I)\mathbf{v}_1 = \mathbf{0}$	$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$	이 방향으로 공간이 5배 팽창함
제2 고유벡터	$(A - 2I)\mathbf{v}_2 = \mathbf{0}$	$\mathbf{v}_2 = \begin{bmatrix} 1 \\ -2 \end{bmatrix}$	이 방향으로 공간이 2배 팽창함

대각화(Diagonalization)

대각화는 행렬 A를 고유벡터를 기준축으로 삼는 새로운 좌표계에서 바라보는 것입니다. 이를 통해 고유벡터 좌표계에서 A는 오직 각 축 방향으로 늘리거나 줄이기만 하는 대각 행렬($\mathbf{\Lambda}$)로 변합니다.

대각화를 하는 이유

1. 연산의 간소화

$$\mathbf{\Lambda}^k = \begin{bmatrix} \lambda_1^k & 0 & \\ 0 & \lambda_2^k & 0 \\ 0 & 0 & \lambda_3^k \end{bmatrix} \tag{2}$$

일반적인 행렬의 거듭제곱(A^k)은 엄청난 계산량을 요구하지만, 대각화된 행렬은 주대각선 원소들만 거듭제곱하면 됩니다.

2. 안정성 분석

고유치(λ)의 크기를 확인하는 것만으로, 시간이 흐를수록 값이 폭주할지($|\lambda| > 1$) 아니면 수렴할지($|\lambda| < 1$) 예측할 수 있습니다.

대각화가 성립하기 위한 조건

$n \times n$ 행렬 A가 대각화 가능하기 위해서는 n개의 선형 독립인 고유벡테를 가져야 합니다. 즉, 고유벡터들로 만든 행렬 $\mathbf{V}$의 역행렬($\mathbf{V}^{-1}$)이 존재해야만 대각화가 성립합니다.

분석 항목	대각화 가능	대각화 불가능
행렬 A	$\begin{bmatrix} 1 & 1 \\ 0 & 2 \end{bmatrix}$	$\begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix}$
고유치 (λ)	$1, 2$ (서로 다름)	$2, 2$ (중근)
고유벡터 개수	2개 (선형 독립)	1개 (부족)
대각화 가능성	가능 (V 가역)	불가능 (V 비가역)

대각화는 단순히 행렬을 분해하는 것에 그치지 않고, 행렬의 복잡한 연산을 고유값들의 단순한 산술 연산으로 바꾸어줍니다.

- Trace 및 Determinant

분석 항목	행렬 A 기준 계산	고유값(λ) 기준 계산	검증 결과
Trace	$3 + 2 = 5$	$\lambda_1 + \lambda_2 = 3 + 2 = 5$	**일치**
Determinant	$(3 \times 2) - 0 = 6$	$\lambda_1 \times \lambda_2 = 3 \times 2 = 6$	**일치**

- 멱승 행렬(A^k)

행렬을 거듭제곱하더라도 그 행렬이 가진 고유벡터는 변하지 않으며, 변환의 강도인 변화값만 k제곱됩니다.

분석 항목	계산 수식 및 과정	수치 결과	전문적 해석
A^2 행렬 직접 계산	$\begin{bmatrix} 3 & 1 \\ 0 & 2 \end{bmatrix}^2$	$\begin{bmatrix} 9 & 5 \\ 0 & 4 \end{bmatrix}$	변환이 두 번 연속 적용된 결과
고유값의 변화	λ_i^2	$3^2 = 9, \quad 2^2 = 4$	고유값은 거듭제곱에 비례하여 변화
고유벡터의 유지	$A^2\mathbf{v}_2$	$4 \cdot \begin{bmatrix} -1 \\ 1 \end{bmatrix}$	변환의 '주축(방향)'은 A와 동일함
대각화 공식 검증	$V\Lambda^2V^{-1}$	$\begin{bmatrix} 9 & 5 \\ 0 & 4 \end{bmatrix}$	대각화를 통한 고속 연산 가능성 증명

5.1.2 스펙트럼 정리(Spectral Theorem)

스펙트럼 정리는 행렬 A가 대칭행렬($A = A^\top$)일 때, 그 행렬을 직교 행렬($\mathbf{V}$)과 대각 행렬($\mathbf{\Lambda}$)로 분해할 수 있다는 정리입니다.

$$\mathbf{A} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^{\mathrm{T}} \tag{3}$$

여기서 가장 중요한 포인트는 $\mathbf{V}$가 직교 행렬이라는 점입니다. 직교 행렬은 고유벡터들이 서로 수직이면서 길이는 1인 상태입니다. 따라서 원래는 복잡한 연산을 거쳐야 하는 역행렬이 전치 행렬과 같아지게 됩니다.

$$\mathbf{V}^{\mathrm{T}}\mathbf{V} = \mathbf{I} \quad \Longrightarrow \quad \mathbf{V}^{\mathrm{T}} = \mathbf{V}^{-1} \tag{4}$$

$$A = \begin{bmatrix} 3 & 2 \\ 2 & 3 \end{bmatrix} \tag{5}$$

고유치 및 정규 직교 고유벡터 도출

고유치 (λ)	고유벡터 방정식	기본 고유벡터 ($\mathbf{x}$)	정규화 ($\mathbf{v}$)
$\lambda_1 = 5$	$(A - 5I)\mathbf{x} = 0$	$\begin{bmatrix} 1 \\ 1 \end{bmatrix}$	$\begin{bmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{bmatrix}$
$\lambda_2 = 1$	$(A - 1I)\mathbf{x} = 0$	$\begin{bmatrix} -1 \\ 1 \end{bmatrix}$	$\begin{bmatrix} -1/\sqrt{2} \\ 1/\sqrt{2} \end{bmatrix}$

스펙트럼 정리 검증 ($\mathbf{A} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^{\mathrm{T}}$)

- $\mathbf{V}$(직교 행렬): $\frac{1}{\sqrt{2}}\begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix}$
- $\mathbf{\Lambda}$ (대각 행렬): $\begin{bmatrix} 5 & 0 \\ 0 & 1 \end{bmatrix}$
- 결과: $\mathbf{V}\mathbf{\Lambda}\mathbf{V}^{\mathrm{T}} = \begin{bmatrix} 3 & 2 \\ 2 & 3 \end{bmatrix}$

스펙트럼 분해

성분	수식	결과 행렬
성분 1	$5\mathbf{v}_1\mathbf{v}_1^T$	$\begin{bmatrix} 2.5 & 2.5 \\ 2.5 & 2.5 \end{bmatrix}$
성분 2	$1\mathbf{v}_2\mathbf{v}_2^T$	$\begin{bmatrix} 0.5 & -0.5 \\ -0.5 & 0.5 \end{bmatrix}$
합계	A	$\begin{bmatrix} 3 & 2 \\ 2 & 3 \end{bmatrix}$

5.2 특이값 분해 (Singular Value Decomposition, SVD)

특이값 분해(SVD)는 행렬 를 3가지 행렬의 곱 (U, Σ, $V^\top$)으로 쪼개는 방법입니다. 앞서 배운 대각화나 스펙트럼 정리가 정방행렬이나 대칭행렬과 같은 조건을 요구했다면, SVD는 모든 행렬에 예외 없이 적용할 수 있는 일반화된 분해법입니다.

5.2.1 기하학적 관찰 (A Geometric Observation)

SVD를 기하학적으로 해석하면 행렬 A라는 선형변환이 공간을 어떻게 찌그러뜨리고 회전시키는가에 대한 답을 제공합니다.

SVD의 기하학적 의미

SVD는 모든 $m \times n$ 행렬 A를 입력의 회전(V^T), 크기 변환(Σ), 출력의 회전(U)이라는 세 단계로 분해합니다. 행렬 A를 $U\Sigma V^\top$로 분해한다는 것은, 아무리 복잡한 변환이라도 다음의 세 가지 기하학적 동작으로 설명할 수 있다는 의미입니다.

- V^T(입력 공간의 회전): 입력 공간의 단위구를 회전시켜, 행렬 A가 가장 크게 잡아당길 방향($v1, v2$,...)을 좌표축과 일치하도록 정렬합니다.
- Σ: 정렬된 축들을 특이값($\sigma 1, \sigma 2$),...만큼 잡아늘리거나 줄입니다. 이 과정에서 원이 타원체가 됩니다. 이때 가장 긴 축의 길이가 곧 가장 큰 특이값입니다.
- U (출력 공간의 회전):만들어진 타원체를 출력 공간의 방향에 맞게 회전시킵니다. 이때 타원체의 주축 방향이 바로 왼쪽 특이벡터($\mathbf{u}_1, \mathbf{u}_2, \ldots$)가 됩니다.

$$A\mathbf{v}_i = \sigma_i \mathbf{u}_i \tag{6}$$

입력 방향 $\mathbf{v}_i$는 행렬 A를 통과하면 σ_i만큼 늘어나서 출력 방향 $\mathbf{u}_i$가 됩니다.

Full SVD로의 확장

축약 SVD는 행렬 A가 실제로 영향을 미치는 성분들만 계산에 포함합니다. 예를 들어 3×2 행렬이라면, 입력 공간은 2차원이지만 출력 공간은 3차원입니다. 하지만 이 행렬이 실제로 만들어낼 수 있는 결과물은 3차원 공간 속의 2차원 평면에 불과합니다.

여기서 축약 SVD는 바로 이 실제로 존재하는 2차원 평면을 설명하는 데 필요한 2개의 축(u_1, u_2)만 남기고 나머지 1차원 방향은 버립니다.

반면 Full SVD는 행렬 A가 직접 관여하지 않는 나머지 공간까지 모두 설명하고자 합니다. 앞서 든 3×2 행렬의 예시에서, Full SVD는 A가 만들어내는 2차원 평면뿐만 아니라, 그 평면에 수직인 나머지 1차원 축(u_3)까지 찾아내어 3×3 정방 행렬을 완성합니다. 비록 이 새로운 축(u_3)에 대응하는 특이값이 0이라서 실제 결과값에는 아무런 영향을 주지 못하더라도, 출력 공간인 3차원 전체를 채우는 기저를 제공한다는 점에서 의미가 있습니다.

$$A = \begin{bmatrix} 3 & 0 \\ 0 & 2 \\ 0 & 0 \end{bmatrix} \tag{7}$$

- 축약 SVD

$$\begin{bmatrix} 3 & 0 \\ 0 & 2 \\ 0 & 0 \end{bmatrix} = \underbrace{\begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}}_{\hat{U}} \underbrace{\begin{bmatrix} 3 & 0 \\ 0 & 2 \end{bmatrix}}_{\hat{\Sigma}} \underbrace{\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}}_{V^T} \tag{8}$$

정보가 있는 $n = 2$개의 열벡터(u_1, u_2)만 사용하여 A를 복원합니다.

- Full SVD

$$\begin{bmatrix} 3 & 0 \\ 0 & 2 \\ 0 & 0 \end{bmatrix} = \underbrace{\begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}}_{U} \underbrace{\begin{bmatrix} 3 & 0 \\ 0 & 2 \\ 0 & 0 \end{bmatrix}}_{\Sigma} \underbrace{\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}}_{V^T} \tag{9}$$

출력 공간 $\mathbb{R}^3$ 전체를 설명하기 위해 수직인 축(u_3)을 추가합니다. 새로 추가된 U의 3번째 열 $\begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$은 Σ의 3번째 행 $[0, 0]$과 곱해져 0이 되므로 결과에 영향을 주지 않습니다.

항목	축약 SVD	Full SVD
U 크기	3×2 (필요한 축만)	3×3 (전체 공간의 축)
Σ 크기	2×2	3×2 (0행 포함)
수학적 가치	**데이터 압축 및 실무 효율성**	**공간 구조 분석 및 이론적 완전성**

5.2.2 SVD 이론 (Theory of the SVD)

복소공간에서의 SVD

복소 공간에서의 SVD는 실수 공간에서의 SVD 개념을 그대로 가져오되, 행렬의 성분이 복소수이므로 직교성과 전치의 개념만 복소수에 맞게 확장합니다.

$$A = \begin{bmatrix} 0 & i \\ 0 & 0 \end{bmatrix} \tag{10}$$

단계	주요 계산 내용	결과값 및 수식	비고
기본 설정	대상 행렬 A 및 켤레 전치 A^*	$A = \begin{bmatrix} 0 & i \\ 0 & 0 \end{bmatrix}, A^* = \begin{bmatrix} 0 & 0 \\ -i & 0 \end{bmatrix}$	$i^* = -i$
Step 1	A^*A 계산	$A^*A = \begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix}$	고유치 $\lambda = \{1, 0\}$
Step 2	특이값(σ) 결정	$\sigma_1 = 1, \sigma_2 = 0$	항상 실수값
Step 3	오른쪽 특이벡터 (V)	$V = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$	A^*A의 고유벡터
Step 4	AA^* 계산	$AA^* = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$	치역 방향 결정
Step 5	왼쪽 특이벡터 (U)	$U = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$	AA^*의 고유벡터

$$U\Sigma V^* = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix} \tag{11}$$

5.2.3 SVD와 기본 공간 (SVD and Fundamental Subspaces)

행렬 A의 랭크가 r일 때, SVD 결과인 U와 V를 정보가 있는 부분(1~r)과 정보가 없는 부분($r+1$~끝)으로 나누면 다음과 같은 관계가 성립합니다.

행렬	분할 행렬	열 벡터	역할
$\mathbf{U}$ ($m \times m$)	$\mathbf{U}_1$ (r개) $\mathbf{U}_2$ ($m-r$개)	$\mathbf{u}_1, \ldots, \mathbf{u}_r$ $\mathbf{u}_{r+1}, \ldots, \mathbf{u}_m$	$\mathbb{R}^m$ 공간을 분할합니다.
$\mathbf{V}$ ($n \times n$)	$\mathbf{V}_1$ (r개) $\mathbf{V}_2$ ($n-r$개)	$\mathbf{v}_1, \ldots, \mathbf{v}_r$ $\mathbf{v}_{r+1}, \ldots, \mathbf{v}_n$	$\mathbb{R}^n$ 공간을 분할합니다.

분할된 벡터들($\mathbf{u}_i, \mathbf{v}_i$)이 네 가지 기본 공간의 **정규 직교 기저**를 이룹니다.

부분공간 명칭	위치 공간	SVD를 통한 기저	차원 ( )	해석
열공간 ($\mathcal{R}(\mathbf{A})$)	$\mathbb{R}^m$	$\mathbf{U}_1$ ($\mathbf{u}_1, \ldots, \mathbf{u}_r$)	r	$\mathbf{A}$가 **만들 수 있는 모든 결과** 벡터의 공간입니다.
좌측 영공간 ($\mathcal{N}(\mathbf{A}^{\mathrm{T}})$)	$\mathbb{R}^m$	$\mathbf{U}_2$ ($\mathbf{u}_{r+1}, \ldots, \mathbf{u}_m$)	$m-r$	$\mathcal{R}(\mathbf{A})$에 **직교하는 여분 공간**입니다.

부분공간 명칭	위치 공간	SVD를 통한 기저	차원 ($\dim$)	해석
행공간 ($\mathcal{R}(\mathbf{A}^{\mathrm{T}})$)	$\mathbb{R}^n$	$\mathbf{V}_1$ ($\mathbf{v}_1, \ldots, \mathbf{v}_r$)	r	$\mathbf{A}$의 **유효한 입력 정보**의 공간입니다.
영공간 ($\mathcal{N}(\mathbf{A})$)	$\mathbb{R}^n$	$\mathbf{V}_2$ ($\mathbf{v}_{r+1}, \ldots, \mathbf{v}_n$)	$n-r$	$\mathbf{A}$에 의해 **영벡터로 변환되어 사라지는** 정보의 공간입니다.

I. 연습 문제 (Problems)

문제 1

다음 행렬 $\mathbf{A}$의 고유치(λ)**를 구하고, $\mathbf{A}$가** 대각화 가능한지 판단하시오.

$$\mathbf{A} = \begin{bmatrix} 4 & 0 \\ 0 & 3 \end{bmatrix} \tag{12}$$

문제 2

행렬 $\mathbf{A}$의 고유치가 $\lambda_1 = 3, \lambda_2 = -1$이고, 해당 고유벡터가 $\mathbf{v}_1, \mathbf{v}_2$일 때, $\mathbf{A}^3$의 **고유치**와 **고유벡터**를 각각 서술하시오.

문제 3

임의의 5×4 행렬 $\mathbf{A}$의 특이값이 $\mathbf{\Sigma} = \mathrm{diag}(10, 5, 2, 0)$일 때, 다음을 구하시오.

1. 행렬 $\mathbf{A}$의 **랭크(r)**
2. $\mathbf{A}$의 **2-노름** ($\|\mathbf{A}\|_2$)

문제 4

위 문제 3의 행렬 $\mathbf{A}$를 랭크 $k = 2$의 행렬 $\mathbf{A}_2$로 근사했을 때, 발생하는 최소 오차($\|\mathbf{A} - \mathbf{A}_2\|_2$)의 값을 구하고, 이 오차가 어떤 특이값과 관련되는지 설명하시오.

II. 해설 (Solutions)

해설 1

1. **고유치:** $\lambda_1 = 4, \lambda_2 = 3$
2. **대각화 가능성:** $\mathbf{A}$는 이미 대각 행렬이며, $\mathbf{A}$는 **대각화 가능합니다.**

해설 2

1. $\mathbf{A}^3$**의 고유치:** $\lambda_1' = 3^3 = \mathbf{27}$, $\lambda_2' = (-1)^3 = \mathbf{-1}$
2. $\mathbf{A}^3$**의 고유벡터:** 원래 행렬 $\mathbf{A}$의 고유벡터인 $\mathbf{v}_1$**과** $\mathbf{v}_2$를 그대로 가집니다.

해설 3

1. **행렬** $\mathbf{A}$**의 랭크 (**r**):** 0이 아닌 특이값은 10, 5, 2로 3개이므로, $r = 3$입니다.
2. $\mathbf{A}$**의 2-노름 (**$\|\mathbf{A}\|_2$**):** 가장 큰 특이값과 같으므로, $\sigma_1 = \mathbf{10}$입니다.

해설 4

$\mathbf{A}$를 랭크 $k = 2$로 근사했을 때, 최소 오차는 버려진 특이값 중 가장 큰 값(σ_{k+1})과 같습니다.

1. **최소 오차:** $\sigma_{k+1} = \sigma_3 = \mathbf{2}$
2. **오차 관련성:** 이 오차는 $\mathbf{A}$의 **세 번째 특이값(**σ_3**)**과 관련되며, 이는 근사에서 제외된 세 번째 주성분에 의한 최대 손실을 의미합니다.