6장 주성분분석법(Principal Component Analysis)

written by Han Suebin

현대의 데이터는 변수가 수천 개에 달하는 고차원 공간에 놓여 있습니다. 하지만 이 모든 변수가 다 중요한 것은 아닙니다.

차원의 저주 (Curse of Dimensionality)

차원이 늘어날수록 데이터가 차지하는 공간 대비 데이터의 밀도는 낮아집니다. 넓은 운동장에 모래알 몇 개를 뿌려 놓은 것과 같아집니다.

- 과적합(Overfitting): 데이터 사이의 빈 공간이 너무 많아져서, 모델이 우연한 노이즈까지 학습하여 일반화 능력이 떨어집니다.
- 분포 추정의 어려움: 데이터들이 너무 멀리 떨어져 있어, 이들이 어떤 분포를 이루고 있는지 판단하기가 힘들어집니다.
- 비효율성: 시간 및 공간 복잡도가 비효율적으로 늘어납니다.

차원 축소: 선택 vs 추출

차원의 저주를 피하기 위해 변수의 개수를 줄여야 합니다. 이때 두 가지 방법이 있습니다.

구분	특징 선택 (Feature Selection)	특징 추출 (Feature Extraction)
핵심 개념	쓸모없는 놈은 버린다	잘 섞어서 핵심 요약본을 만든다
원본 유지	원본 변수가 그대로 살아있음	원본 변수는 사라지고 새로운 변수 탄생
동작 방식	5개 중 중요한 2개만 골라 쓰기	5개를 조합해 새로운 주성분 2개 만들기
장점	해석이 매우 쉬움 (ex. 급여가 중요하다)	정보 손실이 적고 데이터의 본질 파악에 유리

6.2 주성분분석법 (Principal Component Analysis)

주성분 분석(PCA)은 고차원 데이터 속에 숨겨진 가장 중요한 방향을 찾아내는 기법입니다. 직교 변환(Orthogonal Projection)을 활용하여, 데이터의 분산을 최대화하는 새로운 좌표계를 구축합니다.

PCA의 창시자 해럴드 호텔링(Harold Hotelling)은 "데이터의 분산이 곧 정보의 양이다"라고 정의했습니다. 데이터가 널리 퍼져 있을수록 그 축은 데이터를 구분하는 중요한 정보가 됩니다.

- PC1 (첫 번째 주성분): 데이터의 분산이 가장 큰 방향.

- PC2 (두 번째 주성분): PC1과 수직이면서, 남은 변동을 가장 잘 설명하는 방향.

이 과정을 데이터의 차원 수만큼 반복하여 서로 직교하는 새로운 좌표계를 만듭니다.

PCA는 데이터를 새로운 주성분(Principal Component) 축으로 변환함으로써 다음과 같은 중요한 이점을 얻습니다.

- 다중공선성 제거: 새로운 축들이 서로 수직이므로 상관관계가 0이 되어 독립적인 분석이 가능해집니다.
- 해석 가능성: 원본 변수들의 조합을 통해 새로운 의미를 도출할 수 있습니다.
- 차원 축소: 분산이 작은 하위 주성분들을 버림으로써 압축적인 데이터 표현이 가능합니다.

6.2.1 첫 번째 주성분 (First Principal Component)

첫 번째 주성분을 찾는 과정은 데이터를 어떤 선에 투영했을 때 가장 널리 퍼질지를 결정하는 과정입니다.

1. 평균 중심화 (Mean-Centering)

가장 먼저 행해야 할 작업은 데이터의 중심을 원점으로 옮기는 것입니다. 데이터의 절대적인 위치는 중요하지 않기 때문에 순수 변동성만을 계산할 수 있도록 데이터의 중심을 좌표계의 원점으로 이동시킵니다.

$$\sum_{i=1}^{N} \boldsymbol{x}_i = 0 \tag{1}$$

2. 투영 (Projection)

데이터 x_i를 우리가 찾고자 하는 주성분 방향의 단위 벡터 v 위로 정사영하면, 새로운 좌표값 z_i를 얻게 됩니다.

- 새로운 좌표값: $z_i = x_i^T v$
- 전체 좌표 벡터: $z = Xv$

데이터 x_i를 v 방향으로 정사영($P_v x_i$)했을 때, 점들이 선 위에서 서로 멀리멀리 떨어져 있을수록 원본 데이터가 가진 정보를 더 선명하게 파악할 수 있습니다. 반대로 점들이 한곳에 뭉쳐 보인다면, 데이터의 특징을 제대로 포착하지 못한 것입니다.

표본분산의 최대화 문제

PCA는 데이터를 어떤 축(v)으로 정사영해야 정보 손실이 가장 적을까에 대해 답하는 과정입니다. 정보 손실이 적다는 것은 데이터가 가진 변동성(분산)을 최대한 보존한다는 뜻으로, $\mathrm{var}(\mathbf{z}) = \mathbf{v}^\top \mathbf{C}\mathbf{v}$를 최대화하는 것과 같습니다.

앞서 새로운 좌표 벡터 $\mathbf{z} = \mathbf{X}\mathbf{v}$의 분산을 최대화하기 위해 평균이 0인 데이터의 표본 분산 공식에서 시작하여, 행렬 형태로 식을 변형해 봅시다.

$\boldsymbol{z}$에 대한 표본 분산은 다음과 같습니다:

$$\mathrm{var}(\mathbf{z}) = \frac{1}{N-1}\sum_{i=1}^{N} z_i^2 = \frac{1}{N-1}\mathbf{z}^\top\mathbf{z} \tag{2}$$

$\mathbf{z} = \mathbf{X}\mathbf{v}$를 대입하면:

$$\frac{1}{N-1}(\mathbf{X}\mathbf{v})^\top(\mathbf{X}\mathbf{v}) = \frac{1}{N-1}\mathbf{v}^\top\mathbf{X}^\top\mathbf{X}\mathbf{v} \tag{3}$$

여기서 $\frac{1}{N-1}\mathbf{X}^\top\mathbf{X}$ 부분을 공분산 행렬 $\mathbf{C}$라고 부릅니다.

$$\mathrm{var}(\mathbf{z}) = \mathbf{v}^\top\mathbf{C}\mathbf{v} \tag{4}$$

결국 PCA는 $\mathbf{v}^\top\mathbf{C}\mathbf{v}$라는 값을 최대화하는 단위 벡터 $\mathbf{v}$를 찾는 찾는 문제로 요약됩니다.

최적화 문제와 고유값 해석

하지만 벡터 $\mathbf{v}$의 크기를 제한하지 않으면, 단순히 $\mathbf{v}$를 길게 만드는 것만으로도 분산 값은 무한히 커집니다. 우리가 필요한 것은 방향이지 길이가 아니기에 벡터의 길이를 1로 묶어두는 단위 벡터 제약($\mathbf{v}^\top\mathbf{v} = 1$)을 추가해야 합니다.

- 최대화할 목표: $f(\mathbf{v}) = \mathbf{v}^\top\mathbf{C}\mathbf{v}$ (분산)
- 제약: $g(\mathbf{v}) = \mathbf{v}^\top\mathbf{v} - 1 = 0$ (벡터의 길이는 1)

제약 조건이 있는 최적화 문제를 풀기 위해 라그랑주 함수를 설정하고 미분합니다. 그 결과, 고유값 방정식이 나옵니다.

라그랑주 함수 설정: 목표 식에서 제약 조건을 뺀 새로운 함수를 만듭니다.

$$L(\mathbf{v}, \lambda) = \mathbf{v}^\top\mathbf{C}\mathbf{v} - \lambda(\mathbf{v}^\top\mathbf{v} - 1) \tag{5}$$

미분을 통한 임계점 찾기: 함수 L을 변수 $\mathbf{v}$로 미분하여 0이 되는 지점을 찾습니다.

$$\frac{\partial L}{\partial \mathbf{v}} = 2\mathbf{C}\mathbf{v} - 2\lambda\mathbf{v} = 0 \tag{6}$$

고유값 방정식 도출: 위 식을 정리하면 고유값 방정식이 도출됩니다.

$$\mathbf{C}\mathbf{v} = \lambda\mathbf{v} \tag{7}$$

위 식은 공분산 행렬 $\mathbf{C}$에 대한 **고유값 방정식**입니다. 이 식의 양변에 앞쪽에서 $\mathbf{v}^\top$를 곱해보면:

$$\mathbf{v}^\top\mathbf{C}\mathbf{v} = \lambda(\mathbf{v}^\top\mathbf{v}) = \lambda \tag{8}$$

새로운 축 방향의 분산($\mathbf{v}^\top\mathbf{C}\mathbf{v}$)은 해당 축의 고유값($\lambda$)과 정확히 일치합니다. 따라서 분산을 가장 크게 만들고 싶다면, 공분산 행렬 $\mathbf{C}$가 가진 여러 고유값 중 **가장 큰 고유값(λ_1)**을 고르면 됩니다.

이때 대응하는 고유벡터 $\mathbf{v}_1$이 바로 데이터의 정보를 가장 많이 보존하는 첫 번째 주성분 축이 됩니다.

최소 복원오차 (Reconstruction Error Minimization)

데이터 x_i를 축 $\mathbf{v}$로 정사영하면, 데이터는 챙겨야 할 정보와 버릴 정보로 이분법적으로 나뉩니다.

- 정보(정사영 성분): $z_i v$. 데이터를 압축했을 때 남는 데이터입니다.
- 오차 (잔차 성분): $x_i - z_i v$. 축에서 데이터까지의 수직 거리이며, 축 하나로는 설명할 수 없는 손실된 정보입니다.

이 두 성분은 항상 수직을 이루기 때문에 피타고라스의 정리가 성립합니다.

$$\underbrace{\|\mathbf{x}_i\|^2}_{\text{데이터의 총 크기}} = \underbrace{\|\mathbf{x}_i - z_i\mathbf{v}\|^2}_{\text{복원 오차 (수직 거리)}} + \underbrace{z_i^2}_{\text{정사영된 좌표 (분산)}} \tag{9}$$

모든 데이터 샘플(N개)에 대해 합을 취해 보면:

$$\sum_{i=1}^{N} \|\mathbf{x}_i\|^2 = \sum_{i=1}^{N} \|\mathbf{x}_i - z_i\mathbf{v}\|^2 + \sum_{i=1}^{N} z_i^2 \tag{10}$$

- 좌변: 좌변의 $\sum \|\mathbf{x}_i\|^2$는 이미 주어진 데이터의 총 크기이므로, 축을 어떻게 잡든 변하지 않는 고정된 값입니다.
- 우변: 전체 크기가 고정되어 있기 때문에, 분산이 최대화되면 복원 오차는 작아집니다.

6.2.2 추가 주성분 (Further Principal Components)

PCA는 첫 번째 주성분($\mathbf{v}_1$)인 데이터의 가장 큰 분산을 찾고 나면, 그와 직교하는 새로운 축들을 순차적으로 찾아냅니다.

1. 잔차 데이터 생성

k번째 주성분을 찾기 위해 가장 먼저 해야 할 일은, 이미 찾은 k−1개의 축으로 설명 가능한 정보를 원본 데이터에서 빼버리는 것입니다.

$$\boldsymbol{x}_{(k)i} = \boldsymbol{x}_i - \sum_{j=1}^{k-1} (\boldsymbol{x}_i^\top \boldsymbol{v}_j)\boldsymbol{v}_j \in V^\perp, \quad i = 1, \ldots, N \tag{11}$$

2. 분산 최대화와 복원 오차

이제 이 잔차 데이터 행렬 $\boldsymbol{X}_{(k)}$에 대해서 남은 정보 중 어떤 축 $\boldsymbol{v}$에 투영시켜야 가장 넓게 퍼질까를 질문합니다.

$$\|\boldsymbol{x}_{(k)i}\|^2 = \underbrace{\|\boldsymbol{x}_{(k)i} - (\boldsymbol{x}_{(k)i}^\top \boldsymbol{v})\boldsymbol{v}\|^2}_{\text{복원 오차 (오차 성분)}} + \underbrace{\|(\boldsymbol{x}_{(k)i}^\top \boldsymbol{v})\boldsymbol{v}\|^2}_{\text{정사영 성분 (분산)}} \tag{12}$$

이는 결국 원본 행렬 $\boldsymbol{X}$와 주성분들의 합 사이의 거리(Frobenius Norm)를 줄이는 것과 같습니다.

$$\sum_{i=1}^{N} \|\boldsymbol{x}_{(k)i} - (\boldsymbol{x}_{(k)i}^\top \boldsymbol{v})\boldsymbol{v}\|^2 = \|\boldsymbol{X}_{(k)} - \boldsymbol{X}_{(k)}\boldsymbol{v}\boldsymbol{v}^\top\|_F^2 \tag{13}$$

$$\|\boldsymbol{X} - \underbrace{\sum_{j=1}^{k-1} \boldsymbol{X}\boldsymbol{v}_j\boldsymbol{v}_j^\top}_{\text{기존 주성분의 정보}} - \underbrace{\boldsymbol{X}\boldsymbol{v}\boldsymbol{v}^\top}_{\text{새로운 축의 정보}} \|_F^2 \tag{14}$$

6.2.3 주성분의 주요 특성 (Principal Component Properties)

SVD의 각 요소는 PCA의 핵심 구성 요소와 1:1로 대응됩니다.

- 축의 방향 (V): 공분산 행렬의 고유벡터이자, 데이터를 투영할 새로운 주성분 축입니다.
- 데이터의 새 주소 ($U\Sigma$): 원래 복잡했던 데이터 값들이 새로운 축 위에서 어떤 좌표를 갖는지 알려줍니다.
- 크기 (Σ^2): 각 축이 데이터를 얼마나 잘 설명하는지를 나타냅니다.

PCA로 차원을 줄일 때, 축을 몇 개나 남겨야 할지 정해야합니다. 이때 각 주성분이 가진 고유값(λ)을 확인합니다. 고유값은 해당 주성분 방향으로 데이터가 얼마나 넓게 퍼져 있는지를 수치화한 것으로, 선택한 주성분들의 고유값 합이 차지하는 비율 70~80% 정도 되면 핵심은 다 반영하고 있다고 판단합니다.

주성분들의 중요도를 차례대로 그래프로 그리면 처음에는 가파르게 떨어지다가 어느 순간부터 완만해집니다. 이 모양이 마치 팔꿈치처럼 꺾인다고 해서 엘보우(Elbow) 지점이라고 부릅니다.

- 팔꿈치 이전: 데이터의 핵심 특징을 담고 있는 중요한 정보입니다.
- 팔꿈치 이후: 데이터에 섞여 있는 의미 없는 노이즈일 가능성이 높습니다.

I. 연습 문제 (Problems)

문제 1

행렬 $A \in \mathbb{R}^{m\times n}$의 SVD가 $A = U\Sigma V^\top$이고 $rank(A) = r$일 때, 다음 중 **영공간(Null space, $\mathcal{N}(A)$)**의 직교 기저를 포함하는 행렬은 무엇입니까?

- (A) U의 앞쪽 r개 열벡터
- (B) U의 뒤쪽 $m-r$개 열벡터
- (C) V의 앞쪽 r개 열벡터
- (D) V의 뒤쪽 $n-r$개 열벡터

문제 2

어떤 데이터셋의 공분산 행렬을 고유치 분해하여 다음과 같은 고유값을 얻었습니다:

- $\lambda_1 = 5.0, \lambda_2 = 3.0, \lambda_3 = 2.0$

이때, 첫 번째 주성분(PC1)과 두 번째 주성분(PC2)까지 사용하여 차원을 축소했을 때의 누적 설명률은 몇 % 입니까?

문제 3

PCA를 수행하기 전, 모든 데이터에서 평균을 빼주는 **평균 중심화(Mean-Centering)** 작업을 반드시 수행해야 합니다. 만약 이 작업을 생략한다면 주성분 축(PC1)의 방향은 기하학적으로 어떻게 왜곡될 가능성이 높습니까?

문제 4

평균 중심화된 데이터 행렬 X를 SVD 하여 $X = U\Sigma V^\top$를 얻었습니다. 데이터를 새로운 주성분 축으로 변환한 좌표값인 **주성분 점수 행렬** Z를 SVD의 행렬들(U, Σ, V)만 사용하여 수식으로 표현해 보세요.

문제 5

차원 축소된 데이터 Z_c를 다시 원래 차원으로 복원하는 과정($X_{rec} = Z_c V_{:,1:c}^\top$)은 원래 데이터와 완벽히 일치하지 않는 '근사 복원'입니다. 그럼에도 불구하고 이 과정을 통해 얻을 수 있는 **데이터 정제 측면에서의 이점**은 무엇입니까?

II. 해설 (Solutions)

해설 1

정답: (D)

- **이유:** SVD에서 V의 열벡터들은 입력 공간의 기저를 이룹니다. $rank(A) = r$이면 $r+1$번째부터의 특이값은 0입니다. $A\mathbf{v}_i = \sigma_i \mathbf{u}_i$ 관계식에 의해 특이값이 0인 방향의 벡터들은 결과가 $\mathbf{0}$이 되므로, V의 뒤쪽 열벡터들이 영공간의 기저가 됩니다.

해설 2

정답: 80%

- **계산 과정:**
  1. 전체 분산의 총합: $5.0 + 3.0 + 2.0 = 10.0$
  2. 선택된 주성분(PC1, PC2)의 합: $5.0 + 3.0 = 8.0$
  3. 누적 설명률: $(8.0/10.0) \times 100 = 80\%$
- **의미:** 세 개의 변수 중 단 두 개만 사용하더라도 원본 데이터 정보의 80%를 보존할 수 있음을 뜻합니다.

해설 3

정답: PC1이 데이터의 분산 방향이 아닌 '원점에서 데이터 뭉치를 향하는 방향'으로 설정됩니다.

- **이유:** PCA는 원점을 기준으로 데이터가 가장 멀리 퍼진 방향을 찾습니다. 평균 중심화를 하지 않으면 데이터 구름이 원점에서 멀리 떨어져 있을 때, 주성분 축이 데이터 내부의 퍼짐 구조를 잡는 것이 아니라 원점과의 거리를 설명하려 하기 때문에 분석 결과가 왜곡됩니다.

해설 4

정답: $Z = U\Sigma$

- **유도 과정:**
  주성분 점수 Z는 데이터 X를 주성분 축 V로 정사영한 결과이므로 $Z = XV$입니다.
  여기에 SVD 식인 $X = U\Sigma V^\top$를 대입하면:
  $Z = (U\Sigma V^\top)V$
  V는 직교행렬이므로 $V^\top V = I$가 되어 최종적으로 $Z = U\Sigma$가 도출됩니다.

해설 5

정답: 노이즈 제거(Denoising) 및 핵심 패턴 추출

- **이유:** 차원을 축소할 때 버려진 하위 주성분들은 대개 아주 작은 변동, 즉 '잡음'을 포함하고 있습니다. 이를 제외하고 다시 복원하면 원본의 복잡한 노이즈는 사라지고 데이터가 가진 본질적인 뼈대(주요 변동)만 남게 되어 데이터가 더 깨끗해지는 효과를 얻습니다.