

8장 행렬 미적분학(Matrix Calculus)

written by Han Suebin

8.1 미적분학(Calculus)

미적분학은 복잡해 보이지만, 딱 두가지 질문에서 시작되었습니다.

- **미분 (Differentiation):** 이 곡선 위의 한 점에서 기울기(접선)를 어떻게 구할까?
- **적분 (Integration):** 곡선으로 둘러싸인 모양의 넓이를 어떻게 구할까?

처음에는 기울기 구하기(미분)와 넓이 구하기(적분)가 전혀 관계없는 문제처럼 보였습니다. 하지만 미적분학의 기본 정리 덕분에 미분과 적분 이 두가지 개념이 역연산 관계라는 사실이 밝혀졌습니다.

예를 들어, 어떤 함수 f 가 있다고 할 때:

1. 미분하고 나서 적분하면? $\int_0^x \frac{df(t)}{dt} dt = f(x)$ (다시 자기 자신!)

2. 적분하고 나서 미분하면? $\frac{d}{dx} \int_0^x f(t) dt = f(x)$ (역시 다시 자기 자신!)

즉, 미분은 적분을 되돌리고, 적분은 미분을 되돌린다는 것이 핵심입니다.

8.1.1 유클리드 공간 $\mathbb{R}^n$ 의 위상학(Topology of the Euclidean space $\mathbb{R}^n$)

위상학이라는 말은 어렵게 들리지만, 사실 공간의 점들이 어떻게 모여 있고 어디로 향하는지를 탐구하는 분야입니다.

수렴 (Converge)

수열 $\mathbf{x}_k$ 가 어떤 점 $\mathbf{x}$ 로 수렴한다는 것은, 순서대로 점을 찍어봤을 때 결국 그 목표 점에 무한히 가까워진다는 뜻입니다. 예를 들어, 수열 $\mathbf{x}_k = (1 - 2^{-k}, 1/k)^\top$ 가 목표점 $\mathbf{x} = (1, 0)^\top$ 으로 수렴하는 과정을 살펴보겠습니다. 각 단계(k)가 진행됨에 따라 오차가 어떻게 줄어드는지 수치로 확인할 수 있습니다.

단계 (k)	x 성분 ($1 - 2^{-k}$)	y 성분 ($1/k$)	좌표 ($\mathbf{x}_k$)	목표점과의 거리 ($\ \mathbf{x}_k - \mathbf{x}\ $)
$k = 1$	$1 - 0.5 = 0.5$	1.0	(0.5, 1.0)	$\sqrt{0.5^2 + 1.0^2} \approx 1.118$
$k = 2$	$1 - 0.25 = 0.75$	0.5	(0.75, 0.5)	$\sqrt{0.25^2 + 0.5^2} \approx 0.559$
$k = 5$	$1 - 0.03125 \approx 0.969$	0.2	(0.969, 0.2)	$\sqrt{0.031^2 + 0.2^2} \approx 0.202$
$k = 10$	$1 - 0.00097 \approx 0.999$	0.1	(0.999, 0.1)	$\sqrt{0.001^2 + 0.1^2} \approx 0.100$
$k = 100$	$1 - \approx 0 \approx 1.0$	0.01	(1.0, 0.01)	$\sqrt{0^2 + 0.01^2} = 0.010$

각 단계(k)가 진행됨에 따라 오차가 어떻게 줄어드는지 수치로 확인할 수 있습니다.

위상학에서 수렴의 정의인 임의의 $\epsilon > 0$ 에 대하여 자연수 K 가 존재한다는 문장은 단순한 상태 설명이 아니라, 다음과 같은 과정을 의미합니다.

1. 허용 오차(ϵ)의 설정

우리가 원하는 허용 오차를 $\epsilon = 0.1$ 이라고 설정해 봅시다. 이는 목표점 $(1, 0)$ 을 중심으로 반지름이 0.1인 안전 구역을 만드는 것과 같습니다.

2. 임계 지점(K)의 발견

위 수치 표를 보면, $k = 10$ 일 때 거리가 약 0.1에 도달합니다. 즉, 이 수열은 10번째 단계($K = 10$)부터 우리가 정한 안전 구역 안으로 들어오게 됩니다. 중요한 점은 $k = 11, 12, \dots$ 등 그 이후의 모든 단계에서도 절대로 이 구역 밖으로 다시 나가지 않는다는 것입니다.

3. 정밀도의 강화 (Strict ϵ)

만약 정밀도를 10배 높여 $\epsilon = 0.01$ 로 잡는다면 이제 $K = 10$ 은 기준을 만족하지 못합니다. 수열을 더 멀리 보내서 $K = 100$ 이라는 새로운 임계 지점을 찾아내야 합니다.

극한점 (Limit Point)

수열 $\mathbf{x}_k = ((-1)^k, \frac{1}{k})^\top$ 를 생각해 봅시다.

단계 (k)	x 성분 $((-1)^k)$	y 성분 $(1/k)$	좌표 ($\mathbf{x}_k$)	위치 설명
$k = 1$	-1	1.0	$(-1, 1.0)$	왼쪽 위
$k = 2$	1	0.5	$(1, 0.5)$	오른쪽 위
$k = 3$	-1	0.33	$(-1, 0.33)$	왼쪽 위
$k = 4$	1	0.25	$(1, 0.25)$	오른쪽 위
...	...	...	...	...
$k \rightarrow \infty$ (홀수)	-1 유지	0에 수렴	$(-1, 0)$	극한점 1
$k \rightarrow \infty$ (짝수)	1 유지	0에 수렴	$(1, 0)$	극한점 2

이 점들은 k 가 커질수록 바닥($y = 0$)에 붙으면서 왼쪽(-1)과 오른쪽(1)을 왔다 갔다 합니다. 전체는 하나로 모이지 않지만, $(-1, 0)$ 과 $(1, 0)$ 은 무한히 자주 방문하므로 이 둘이 극한점이 됩니다.

상한 및 하한 극한값: $\limsup$ 와 $\liminf$

극한점이 여러 개일 때, 그중 가장 높은 곳과 가장 낮은 곳을 의미합니다.

앞선 예시에서, $r_k = (-1)^k + \frac{1}{k}$

이 수열의 실제 값을 나열해 보면 매우 간단합니다.

0, 1.5, -0.66, 1.25, -0.8, 1.16, ...

1. 상한 극한 ($\limsup r_k = 1$):

- 짝수 항들은 $1.5 \rightarrow 1.25 \rightarrow 1.16 \dots$ 점차 1을 향해 내려옵니다.
- 더 이상 올라갈 수 없는 '천장' 같은 극한점입니다.

2. 하한 극한 ($\liminf r_k = -1$):

- 홀수 항들은 $0 \rightarrow -0.66 \rightarrow -0.8 \dots$ 점차 -1을 향해 내려갑니다.

- 더 이상 내려갈 수 없는 '바닥' 같은 극한점입니다.

열린 집합 (Open Set)과 닫힌 집합 (Closed Set)

집합의 성질은 그 집합이 자신의 테두리를 포함하고 있는지에 따라 결정됩니다. 가장 쉬운 예시인 수직선 위의 구간으로 비교해 보겠습니다.

1. 열린 집합 (Open Set)

- 예시: $S = (0, 1)$ (0과 1 사이의 모든 실수, 단 0과 1은 제외)
- 특징: 이 집합 안의 어떤 점 x 를 골라도, 아주 미세한 반지름 ϵ 을 가진 작은 구간을 만들면 그 구간 전체가 여전히 S 안에 들어갑니다.
- 수치적 이해: $x = 0.001$ 을 골라도, 반지름을 0.0001로 잡으면 $(0.0009, 0.0011)$ 은 여전히 S 안의 점들입니다.
- 내부(Interior): S 자체가 이미 가장 큰 열린 집합이므로 $\text{int}(S) = S$ 입니다.

2. 닫힌 집합 (Closed Set)

- 예시: $S = [0, 1]$ (0과 1을 포함한 사이의 모든 실수)
- 특징: 이 집합 안의 점들로 수열을 만들어서 어딘가로 다가간다면(수렴), 그 목적지(극한점)도 반드시 S 안에 있어야 합니다.
- 수치적 이해: 수열 $x_k = \frac{1}{k}$ 를 생각해 봅시다. 1, 0.5, 0.1, 0.01... 이 점들은 모두 S 안에 있습니다. 이 수열의 목적지인 0 역시 S 에 포함되어 있습니다. 만약 $S = (0, 1)$ 이었다면 목적지인 0이 집합 밖에 있으므로 닫힌 집합이 될 수 없습니다.
- 폐포(Closure): 어떤 집합에 그 한계점(극한점)들까지 다 포함시킨 상태입니다. $S = [0, 1]$ 은 이미 완결되었으므로 $\text{cl}(S) = S$ 입니다.

콤팩트 집합 (Compact Set)

콤팩트 집합은 집합이 닫혀 있고(Closed) 동시에 크기가 제한(Bounded)되어 있다는 뜻입니다.

- 콤팩트한 예: $S = [0, 1]$ (닫힌 구간)
 - 닫힘(closed): 경계값 0과 1을 포함합니다.
 - 유계(bounded): 크기가 1로 딱 정해져 있습니다.
 - 특징: 이 안에서 어떤 수열을 만들어도(예: 0.1, 0.11, 0.111...), 그 목적지는 반드시 S 안에 존재합니다.
- 콤팩트하지 않은 예 1: $S = (0, 1)$ (열린 구간)
 - 유계(bounded)이지만 닫혀(closed) 있지 않습니다. 수열 $1/k$ 의 목적지인 0이 집합에 없기 때문입니다.
- 콤팩트하지 않은 예 2: $S = [0, \infty)$ (반직선)
 - 닫혀(closed) 있지만 유계(bounded)가 아닙니다. 무한히 뻗어 나가기 때문에 수열이 목적지 없이 영원히 방황할 수 있습니다.

근방 (Neighborhood)

어떤 점 $\mathbf{x}$ 의 근방은 그 점을 포함하는 아주 작은 집합입니다.

점 $(1, 1)$ 의 0.1-근방 ($B_{0.1}$)

이 동네에 입주하려면 점 $(1, 1)$ 로부터의 거리가 반드시 0.1 미만이어야 합니다.

- 입주 가능 (이웃):
 - $(1.05, 1.05)$: 거리가 약 0.07이므로 가능.
 - $(1.0, 1.09)$: 거리가 0.09이므로 가능.
- 입주 불가능 :
 - $(1.1, 1.0)$: 거리가 딱 0.1이라서 탈락 (경계선은 제외).
 - $(1.2, 1.2)$: 거리가 0.28이라 너무 멀어서 탈락.

8.1.2 연속과 극한(Continuity and Limits)

함수의 극한과 연속은 입력값이 변할 때 출력값이 얼마나 예측 가능하게(Predictably) 변하는지를 다루는 개념입니다.

$\lim_{\mathbf{x} \rightarrow \mathbf{x}_0} f(\mathbf{x}) = f_0$ 라는 정의는 단순히 가까워진다는 뜻을 넘어, 입력의 정밀도를 조절하여 출력의 오차를 원하는 만큼 줄일 수 있다는 의미를 담고 있습니다.

- 정의 : 임의의 오차 $\epsilon > 0$ 에 대해, $\|\mathbf{x} - \mathbf{x}_0\| < \delta$ 이면 $\|f(\mathbf{x}) - f_0\| < \epsilon$ 가 되도록 하는 정밀도 $\delta > 0$ 를 항상 찾을 수 있어야 합니다.
- 수치적 예시: $f(x) = 3x$ 라고 할 때, $x \rightarrow 2$ 에서의 극한값 $f_0 = 6$ 을 검증해 봅시다.
 - 만약 출력 오차(ϵ)를 0.03 이내로 제한하고 싶다면?
 - $|3x - 6| < 0.03 \Rightarrow 3|x - 2| < 0.03 \Rightarrow |x - 2| < 0.01$
 - 즉, 입력값 x 를 2로부터 0.01 이내(δ)로만 제어하면 출력 오차는 반드시 보장됩니다.

연속성의 정의

함수 f 가 점 $\mathbf{x}_0$ 에서 연속이라는 것은, 해당 지점에서 함수의 그래프가 물리적으로 이어져 있음을 수학적으로 보장하는 것입니다. 이를 위해 다음의 3 조건이 만족되어야 합니다.

조건	수학적 표현	직관적 의미
1. 존재성	$f(\mathbf{x}_0)$ 가 정의됨	해당 위치에 함수값이 실제로 존재해야 함.
2. 수렴성	$\lim_{\mathbf{x} \rightarrow \mathbf{x}_0} f(\mathbf{x})$ 존재	좌/우 또는 사방에서 다가오는 목표치(극한)가 하나로 일치해야 함.
3. 일치성	$\lim f(\mathbf{x}) = f(\mathbf{x}_0)$	다가가는 목표 지점(극한)과 실제 데이터(함숫값)가 일치해야 함.

####

함수가 정의역 D 전체에서 연속이라는 것은, 그 구역 내의 어느 지점을 샘플링하더라도 위 3가지 조건이 완벽하게 충족됨을 의미합니다. 이는 데이터 분석 모델이 입력값의 미세한 변화에 대해 갑작스러운 점프 없이 안정적으로 동작함을 시사합니다.

한쪽 극한 (One-sided Limits, $n = 1$ 인 경우)

1차원 실수 공간($\mathbb{R}$)에서는 점 x_0 에 도달하는 방법이 왼쪽과 오른쪽, 두 가지뿐입니다. 이를 통해 함수의 연속성을 분석할 수 있습니다.

우극한 (Right-hand Limit, $x \downarrow x_0$)

- 의미: x_0 보다 큰 값($x_0 + \delta$)에서 목표지점으로 다가갈 때의 함숫값 변화입니다.
- 수치적 예시: $f(x) = \begin{cases} 2 & (x \geq 0) \\ 1 & (x < 0) \end{cases}$ 일 때, $x = 0$ 에서의 우극한은 2입니다.

좌극한 (Left-hand Limit, $x \uparrow x_0$)

- 의미: x_0 보다 작은 값($x_0 - \delta$)에서 목표지점으로 다가갈 때의 함숫값 변화입니다.
- 수치적 예시: 위와 같은 함수에서 $x = 0$ 의 좌극한은 1입니다.

좌극한과 우극한이 다르면($1 \neq 2$), 이 함수는 해당 지점에서 '도약 불연속(Jump Discontinuity)'이 발생했다고 판단합니다.

립시츠 연속(Lipschitz Continuity)

립시츠 연속은 일반적인 연속보다 훨씬 강력한 조건입니다. 함수의 그래프가 얼마나 가파르게 변할 수 있는지 상한선(M)을 정해두는 것입니다.

쉽게 말해 두 점 사이의 **결과값 차이(Δf)**가 **입력값 차이(Δx)**의 M 배를 넘지 않아야 합니다. 함수의 기울기가 M 이라는 속도 제한에 걸려 있는 상태와 같습니다.

$$\|f(\mathbf{x}_1) - f(\mathbf{x}_0)\| \leq M\|\mathbf{x}_1 - \mathbf{x}_0\| \quad (1)$$

$f(x) = \sqrt{x}$ 는 $[1, 4]$ 에서 립시츠 연속인지 확인해 봅시다.

- 두 점 $x_0 = 1, x_1 = 4$ 를 잡으면, $\|x_1 - x_0\| = 3$ 입니다.
- 함숫값은 $f(1) = 1, f(4) = 2$ 이므로 $\|f(x_1) - f(x_0)\| = 1$ 입니다.
- $1 \leq M \cdot 3$ 을 만족하는 M 을 찾을 수 있습니다. 실제로 이 구간에서 $\sqrt{x}$ 의 최대 기울기는 $x = 1$ 일 때의 0.5이므로, $M = 0.5$ 로 잡으면 모든 점 쌍에 대해 성립합니다.

8.1.3 기울기와 도함수(Slope and Derivative)

미분은 지금 이 순간, 얼마나 빠르게 변하고 있는가?를 측정하는 도구입니다. 평균 변화율에서 순간 변화율로 나아가는 과정을 수치적으로 이해해 봅시다.

기울기(Slope)와 도함수(Derivative)

- 기울기(차분몫): 두 점 사이의 평균적인 변화 속도입니다.
- 도함수: 간격(Δx)을 무한히 줄여서 찾아낸 찰나의 속도입니다.

함수 $f(x) = x^2$ 일 때, $x = 2$ 에서의 기울기와 도함수

간격 (Δx)	이웃한 점 ($x + \Delta x$)	함숫값 차이 (Δf)	기울기 ($\frac{\Delta f}{\Delta x}$)	비고
1.0	3.0	$3^2 - 2^2 = 5$	$5/1 = 5.0$	거친 근사
0.1	2.1	$2.1^2 - 2^2 = 0.41$	$0.41/0.1 = 4.1$	정밀한 근사
0.01	2.01	$2.01^2 - 2^2 = 0.0401$	$0.0401/0.01 = 4.01$	매우 정밀함
$\rightarrow 0$	2	0	$\rightarrow 4.0$	도함수 $f'(2)$

Δx 가 0에 가까워질수록 기울기 값은 4라는 값으로 수렴합니다. 이것이 바로 접선의 기울기이자 도함수 값입니다.

이계도함수(Second Derivative)

이계도함수 $f''(x)$ 는 기울기가 다시 어떻게 변하는지를 측정합니다.

- 수치적 의미:
 - $f''(x) > 0$: 기울기가 점점 가팔라짐 (아래로 볼록, 가속)
 - $f''(x) < 0$: 기울기가 점점 완만해짐 (위로 볼록, 감속)

실함수의 미분법: 곱, 몫, 연쇄법칙

실제 계산에서 자주 쓰이는 세 가지 법칙을 수치 예시로 확인해 보겠습니다. ($f(x) = x^2, g(x) = 3x$ 가정)

1. 곱의 미분법: $(x^2 \cdot 3x)'$ 를 구한다면?

- 공식 적용: $(2x \cdot 3x) + (x^2 \cdot 3) = 6x^2 + 3x^2 = 9x^2$
- 확인: 원래 함수가 $3x^3$ 이므로 미분하면 $9x^2$ 로 일치.

2. 몫의 미분법: $(\frac{x^2}{3x})'$ 를 구한다면? (단, $x \neq 0$)

- 공식 적용: $\frac{(2x \cdot 3x) - (x^2 \cdot 3)}{(3x)^2} = \frac{6x^2 - 3x^2}{9x^2} = \frac{3x^2}{9x^2} = \frac{1}{3}$
- 확인: $\frac{x^2}{3x} = \frac{1}{3}x$ 이므로 미분하면 $\frac{1}{3}$ 로 일치.

3. 연쇄법칙: 합성함수 $f(g(x)) = (3x)^2$ 의 미분은?

- 공식 적용: 겉미분 $f'(g(x)) = 2(3x)$ 에 속미분 $g'(x) = 3$ 을 곱함 $\rightarrow 6x \cdot 3 = 18x$
- 확인: $(3x)^2 = 9x^2$ 이므로 미분하면 $18x$ 로 일치.

8.1.4 편도함수(Partial derivative)

두 변수 함수의 편도함수 (First Partial Derivatives of $f(x, y)$)

편도함수는 다변수 함수 $f(x, y)$ 에서 특정 변수의 영향력만을 독립적으로 분석하기 위한 도구입니다.

1. x 에 대한 편도함수 ($\frac{\partial f}{\partial x}$)

- 핵심: y 를 상수로 간주하고 x 에 대해서만 미분합니다.
- 예시: $f(x, y) = 3x^2y$ 일 때 $(x = 2, y = 5)$ 에서의 값은?
 - x 로 편미분: $\frac{\partial f}{\partial x} = 6xy$
 - 값 대입: $6(2)(5) = 60$
 - 의미: y 가 5로 고정된 상태에서 x 가 아주 미세하게 변하면, 함숫값은 그 변화량의 60배만큼 변합니다.

2. y 에 대한 편도함수 ($\frac{\partial f}{\partial y}$)

- 핵심: x 를 상수로 간주하고 y 에 대해서만 미분합니다.
- 예시: 위와 같은 함수 $f(x, y) = 3x^2y$ 에서,
 - y 로 편미분: $\frac{\partial f}{\partial y} = 3x^2$
 - 값 대입: $3(2^2) = 12$
 - 의미: x 가 2로 고정된 상태에서 y 가 변하면, 함숫값은 그 변화량의 12배만큼 변합니다.

두 변수 함수의 이계 편도함수 (Second-Order Partial Derivatives)

일계 편도함수가 기울기를 알려준다면, 이계 편도함수는 그 기울기가 변하는 방식을 설명합니다.

1. 순수 이계 편도함수 (f_{xx}, f_{yy})

- 의미: 특정 축 방향으로의 **가속도** 또는 **곡률**입니다.
- 예시: $f(x, y) = x^3 + y^2$
 - $f_x = 3x^2 \rightarrow f_{xx} = 6x$
 - $f_y = 2y \rightarrow f_{yy} = 2$

- 해석: y 방향 곡률(f_{yy})은 어디서나 2로 일정하지만, x 방향 곡률(f_{xx})은 x 가 커질수록 점점 더 가팔라집니다.

2. 혼합 이계 편도함수 (f_{xy}, f_{yx})

- 의미: 한 변수의 변화율이 다른 변수의 영향을 얼마나 받는지 측정합니다.
- 수치 예시: $f(x, y) = 5xy + x^2$
 - $f_x = 5y + 2x$
 - 이 결과(f_x)를 y 로 미분하면: $f_{xy} = 5$
- 해석: x 축 방향의 경사는 y 가 1단위 증가할 때마다 5만큼 더 가팔라집니다.

다변수 편도함수

다변수 함수 $f(\mathbf{x})$ 의 미분은 n 개의 서로 독립적인 방향으로의 변화율을 측정하여 하나의 행 벡터(Row Vector)로 통합하는 과정입니다.

- 편도함수와 단위 벡터 ($\mathbf{e}_i$)

특정 성분 x_i 에 대한 편도함수는 해당 방향의 표준 단위 벡터 $\mathbf{e}_i$ 를 이용하여 다음과 같이 표현됩니다.

$$\frac{\partial f}{\partial x_i} = \lim_{\epsilon \rightarrow 0} \frac{f(\mathbf{x} + \epsilon \mathbf{e}_i) - f(\mathbf{x})}{\epsilon} \quad (2)$$

다른 모든 변수는 고정되어 있고, 오직 i 번째 축으로만 아주 살짝 이동했을 때의 높이 변화량입니다.

- 일계 도함수 벡터 (First-order Derivative Vector)

모든 편도함수를 한데 모은 행 벡터 $\frac{\partial f}{\partial \mathbf{x}}$ 는 다변수 함수의 전체적인 기울기 정보를 담고 있습니다.

$$\frac{\partial f}{\partial \mathbf{x}} := \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n} \right) \in \mathbb{R}^{1 \times n} \quad (3)$$

예를 들어, $f(x_1, x_2, x_3) = x_1^2 + x_2 x_3$

점 $\mathbf{x} = (1, 2, 3)^\top$ 에서 각 방향의 기울기를 계산하면 다음과 같습니다.

1. x_1 방향 기울기: $2x_1 = 2$
 2. x_2 방향 기울기: $x_3 = 3$
 3. x_3 방향 기울기: $x_2 = 2$
- 최종 도함수 벡터: $(2 \quad 3 \quad 2)$

다변수 함수의 미분 가능성과 정칙성 클래스 (Differentiability and Regularity Classes)

등급	수식	기울기(f')의 상태	수치적 특징	최적화 도구
미분 불가	$ x $	0에서 정의 안 됨	$x = 0$ 근처에서 방향을 못 잡음	휴리스틱 알고리즘
미분 가능	$x^{1.5}$	$1.5\sqrt{x}$	미분은 되지만 기울기가 급변할 수 있음	단순 탐색
C^1 급	$x^2 + y^2$	$2x, 2y$ (연속)	기울기가 부드럽게 변함 (예측 가능)	경사하강법(GD)
C^2 급	e^{x+y}	모든 이계 미분 연속	굴곡(Hessian) 정보를 믿고 쓸 수 있음	뉴턴 방법 (Newton)

8.2 그래디언트와 헤시안(Gradient and Hessian)

8.2.1 그래디언트 (Gradient)

그래디언트는 다변수 함수 $f(\mathbf{x})$ 의 모든 방향 성분별 기울기를 모아놓은 **열 벡터**입니다.

$$\nabla f(\mathbf{x}) := \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{bmatrix} \quad (4)$$

입력 벡터 $\mathbf{x}$ 와 차원이 동일하므로, 공간 상의 한 점마다 하나의 화살표(방향과 크기)를 대응시킬 수 있습니다.

예를 들어, 함수 $f(x, y) = x^2 + 2y^2$ 의 점 $(1, 1)$ 에서의 그래디언트는 다음과 같습니다.

$$\nabla f(1, 1) = \begin{bmatrix} 2 \\ 4 \end{bmatrix} \quad (5)$$

8.2.2 헤시안 행렬 (Hessian Matrix)

헤시안 행렬은 함수의 이계 편도함수를 모은 정사각 행렬로, 함수의 **국소적 기하 구조**를 설명합니다.

$$\nabla^2 f(\mathbf{x}) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix} \quad (6)$$

헤시안의 대칭성

함수 $f(x, y) = x^2 + 4xy + 2y^2$ 일 때,

- $f_{xy} = \frac{\partial}{\partial y}(2x + 4y) = 4$
- $f_{yx} = \frac{\partial}{\partial x}(4x + 4y) = 4$
- Hessian:** $H = \begin{bmatrix} 2 & 4 \\ 4 & 4 \end{bmatrix}$ (대칭 행렬)

헤시안과 최적화

임계점($\nabla f = 0$)에서 헤시안 H 를 분석합니다.

- 로컬 최소점 (Local Minimum):**
 - 수치 조건: 모든 $\lambda_i > 0$ (예: 2, 5, 10)
 - 어느 방향으로 발을 내디셔도 위로 올라가는 안전한 골짜기입니다.
- 로컬 최대점 (Local Maximum):**
 - 수치 조건: 모든 $\lambda_i < 0$ (예: -1, -4, -8)
 - 사방이 낭떠러지인 산꼭대기와 같습니다.
- 안장점 (Saddle Point):**
 - 수치 조건: λ 중 양수와 음수가 섞여 있음 (예: 3, -2)
 - x 축으로는 골짜기인데 y 축으로는 봉우리인 saddle point 지형입니다. 경사하강법이 가장 빠지기 쉬운 함정입니다.

헤시안의 행렬식(Determinant)과 주대각성분(Trace)으로도 판별할 수 있지만, 고유값은 각 축 방향의 정확한 곡률의 크기까지 알려주기 때문에 가장 자세한 정보를 제공합니다.

8.3 행렬 도함수(Matrix Derivatives)

8.3.1 행렬 도함수(Matrix Derivative)의 표기 체계

행렬 도함수는 복잡한 편미분들을 일정한 규칙에 따라 배열하는 약속입니다. 수치적 예시를 통해 살펴보겠습니다.

1. [벡터 $\rightarrow$ 스칼라] $\frac{\partial y}{\partial \mathbf{x}}$ (결과: $1 \times n$ 행 벡터)

하나의 결과값(y)을 여러 입력 변수($x_1, x_2, \dots$)로 각각 미분하여 **가로**로 나열합니다.

- 수식: $y = 3x_1 + 4x_2$
- Step 1:** 첫 번째 변수 x_1 에 대해 편미분 $\rightarrow \frac{\partial y}{\partial x_1} = 3$
- Step 2:** 두 번째 변수 x_2 에 대해 편미분 $\rightarrow \frac{\partial y}{\partial x_2} = 4$
- Step 3:** 각 결과를 순서대로 행 벡터로 결합 $\rightarrow [3, 4]$

- **차원 확인:** 분자(y)는 1개, 분모(x)는 2개이므로 결과는 1×2 행렬이 됩니다.

2. [스칼라 $\rightarrow$ 벡터] $\frac{\partial y}{\partial x}$ (결과: $m \times 1$ 열 벡터)

여러 출력값($y_1, y_2, \dots$)을 하나의 변수(x)로 각각 미분하여 원래 벡터 모양대로 세로로 나열합니다.

- 수식: $\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \begin{bmatrix} x \\ x^2 \end{bmatrix}$
- **Step 1:** 첫 번째 출력 y_1 을 x 로 미분 $\rightarrow \frac{dy_1}{dx} = 1$
- **Step 2:** 두 번째 출력 y_2 를 x 로 미분 $\rightarrow \frac{dy_2}{dx} = 2x$
- **Step 3:** 각 결과를 순서대로 열 벡터로 결합 $\rightarrow \begin{bmatrix} 1 \\ 2x \end{bmatrix}$
- **차원 확인:** 분자(y)가 2×1 이므로 미분 결과도 2×1 열 벡터입니다.

3. [벡터 $\rightarrow$ 벡터] $\frac{\partial \mathbf{y}}{\partial \mathbf{x}}$ (결과: $m \times n$ 행렬)

각 출력 성분(y_i)을 각 입력 성분(x_j)으로 미분하여 표(자코비안 행렬)를 만듭니다.

- 수식: $\mathbf{y} = A\mathbf{x} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} x_1 + 2x_2 \\ 3x_1 + 4x_2 \end{bmatrix}$
- **Step 1 (1행 작성):** 첫 번째 출력 $y_1 = x_1 + 2x_2$ 를 벡터 $\mathbf{x}$ 로 미분 $\rightarrow [1, 2]$
- **Step 2 (2행 작성):** 두 번째 출력 $y_2 = 3x_1 + 4x_2$ 를 벡터 $\mathbf{x}$ 로 미분 $\rightarrow [3, 4]$
- **Step 3:** 각 행을 차례대로 쌓아 행렬 완성 $\rightarrow \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$
- **차원 확인:** 분자($m = 2$)와 분모($n = 2$)의 영향으로 2×2 행렬이 됩니다. (A 행렬이 그대로 유지됨)

4. [행렬 $\rightarrow$ 스칼라] $\frac{\partial z}{\partial X}$ (결과: $p \times q$ 행렬)

최종 결과값(z)을 행렬의 각 원소(x_{ij})로 미분하여 원래 원소가 있던 위치에 결과값을 배치합니다.

- 수식: $z = \text{tr}(AX) = \text{tr} \left(\begin{bmatrix} a & b \\ c & d \end{bmatrix} \begin{bmatrix} x_{11} & x_{12} \\ x_{21} & x_{22} \end{bmatrix} \right) = ax_{11} + bx_{21} + cx_{12} + dx_{22}$
- **Step 1:** 각 성분별 편미분 수행
 - $\frac{\partial z}{\partial x_{11}} = a, \quad \frac{\partial z}{\partial x_{12}} = c$
 - $\frac{\partial z}{\partial x_{21}} = b, \quad \frac{\partial z}{\partial x_{22}} = d$
- **Step 2:** 결과를 행렬 X 와 똑같은 위치에 배치 $\rightarrow \begin{bmatrix} a & c \\ b & d \end{bmatrix}$
- **Step 3:** 결과 관찰 $\rightarrow \begin{bmatrix} a & b \\ c & d \end{bmatrix}^\top = A^\top$
- **차원 확인:** 분모인 행렬 X 가 2×2 이므로 미분 결과 역시 2×2 행렬입니다.

[꿀팁]

1. **모양 보존의 법칙:** 스칼라를 행렬 X 로 미분하면 결과는 무조건 X 와 똑같은 모양이어야 합니다.

2. **분자 중심의 원칙**: 결과 행렬의 행(Row) 개수는 항상 분자($\mathbf{y}$)의 차원과 일치합니다.
3. **성분별 배치**: 행렬 미분이 헛갈릴 때는 위와 같이 성분별로 하나씩 미분해서 제자리에 놓는다고 생각하면 실수를 줄일 수 있습니다.

8.3.2 야코비안 (Jacobian)

야코비안 행렬은 다변수 함수가 입력의 미세한 변화에 대해 출력 벡터를 어떻게 변화시키는지 보여주는 선형 변환 지도입니다.

1. 벡터의 야코비안 ($\mathbf{y} = A\mathbf{x}$)

가장 기본이 되는 형태로, n 차원 입력을 m 차원 출력으로 보내는 선형 사상을 미분해 보겠습니다.

$$A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \text{이고 } \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \text{일 때} \quad (7)$$

$$\mathbf{y} = A\mathbf{x} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} x_1 + 2x_2 \\ 3x_1 + 4x_2 \end{bmatrix} \text{입니다.} \quad (8)$$

- Step 1: y_1 에 대한 미분 (결과 행렬의 1행)

$$\circ \frac{\partial y_1}{\partial x_1} = 1, \quad \frac{\partial y_1}{\partial x_2} = 2 \rightarrow [1, 2]$$

- Step 2: y_2 에 대한 미분 (결과 행렬의 2행)

$$\circ \frac{\partial y_2}{\partial x_1} = 3, \quad \frac{\partial y_2}{\partial x_2} = 4 \rightarrow [3, 4]$$

- 최종 결과: $\frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} = A$

일변수 함수 $y = ax$ 의 기울기가 a 인 것과 마찬가지로, 벡터 함수의 선형 변환 계수인 행렬 A 자체가 바로 야코비안이 됩니다.

2. 행렬에 대한 행렬의 미분

행렬 $Y(m \times n)$ 를 행렬 $X(p \times q)$ 로 미분하면, X 의 모든 성분(pq 개)이 Y 의 모든 성분(mn 개)에 미치는 영향을 각각 구해야 합니다. 총 $mn \times pq$ 개의 미분값이 존재하게 되는데, 이를 원래 위치대로 나열하면 **4차원 텐서(4th-order tensor)**가 됩니다.

- 입력 성분: $p \times q$ 개
- 출력 성분: $m \times n$ 개
- 총 관계 수: $(m \times n) \times (p \times q)$ 개
- 이 방대한 양의 데이터를 원래의 행렬 구조를 유지하며 저장하려면 4개의 인덱스(4차원)가 필요합니다.

그러나 컴퓨터는 4차원 구조를 이해하지 못합니다. 그래서 행렬을 벡터로 펼칩니다.

- X 를 펼치면 $\mathbb{R}^{pq \times 1}$ 벡터가 됩니다.
- Y 를 펼치면 $\mathbb{R}^{mn \times 1}$ 벡터가 됩니다.

- 이제 미분 결과는 단순한 $mn \times pq$ 크기의 2차원 행렬이 됩니다.

8.3.3 유용한 행렬 도함수(Useful matrix derivative)

행렬 미분 공식은 일변수 미분의 직관을 유지하되, 차원(Dimension)과 전치(Transpose)에 주의하는 것이 핵심입니다.

선형 함수 (Linear Function): $f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x}$

가장 기본적인 일차 형태의 스칼라 함수입니다.

- 수치 설정: $\mathbf{a} = \begin{bmatrix} 3 \\ 5 \end{bmatrix}, \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$
- 함수 전개: $f(\mathbf{x}) = \begin{bmatrix} 3 & 5 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 3x_1 + 5x_2$
- 원리 (성분별 미분):
 1. x_1 에 대해 편미분: $\frac{\partial f}{\partial x_1} = \frac{\partial}{\partial x_1}(3x_1 + 5x_2) = 3$
 2. x_2 에 대해 편미분: $\frac{\partial f}{\partial x_2} = \frac{\partial}{\partial x_2}(3x_1 + 5x_2) = 5$
- 그래디언트(∇f): $\nabla f = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \end{bmatrix} = \begin{bmatrix} 3 \\ 5 \end{bmatrix} = \mathbf{a}$
- 헤시안($\nabla^2 f$) 도출:
 1. $\frac{\partial^2 f}{\partial x_1^2} = \frac{\partial}{\partial x_1}(3) = 0$
 2. $\frac{\partial^2 f}{\partial x_1 \partial x_2} = \frac{\partial}{\partial x_2}(3) = 0$

◦ 결과값이 상수이므로 모든 이계 도함수는 0이 되어 $\nabla^2 f = \mathbf{0}$ 입니다.

2차 노름 제곱 (Squared L2 Norm): $f(\mathbf{x}) = \|\mathbf{x}\|^2 = \mathbf{x}^\top \mathbf{x}$

변수들의 제곱합으로 이루어진 함수로, 최적화에서 가장 흔히 쓰이는 형태입니다.

- 수치 설정: $\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$
- 함수 전개: $f(\mathbf{x}) = \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = x_1^2 + x_2^2$
- 원리 (성분별 미분):
 1. x_1 에 대해 편미분: $\frac{\partial f}{\partial x_1} = \frac{\partial}{\partial x_1}(x_1^2 + x_2^2) = 2x_1$
 2. x_2 에 대해 편미분: $\frac{\partial f}{\partial x_2} = \frac{\partial}{\partial x_2}(x_1^2 + x_2^2) = 2x_2$
- 그래디언트(∇f): $\nabla f = \begin{bmatrix} 2x_1 \\ 2x_2 \end{bmatrix} = 2 \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 2\mathbf{x}$
- 헤시안($\nabla^2 f$) 도출:

1. $f_{x_1x_1} = \frac{\partial}{\partial x_1}(2x_1) = 2$
 2. $f_{x_1x_2} = \frac{\partial}{\partial x_2}(2x_1) = 0$
 3. $f_{x_2x_1} = \frac{\partial}{\partial x_1}(2x_2) = 0$
 4. $f_{x_2x_2} = \frac{\partial}{\partial x_2}(2x_2) = 2$
- 결과 행렬: $\begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} = 2\mathbf{I}$ (모든 방향으로 일정한 곡률 2를 가짐)

이차형식 (Quadratic Form): $f(\mathbf{x}) = \mathbf{x}^\top A \mathbf{x}$

행렬 A 에 의해 정의되는 일반적인 2차 함수 형태입니다.

- 수치 설정 (A 가 비대칭일 때): $A = \begin{bmatrix} 1 & 2 \\ 0 & 3 \end{bmatrix}, \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$
- 함수 전개: $f(\mathbf{x}) = \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} x_1 + 2x_2 \\ 3x_2 \end{bmatrix} = x_1^2 + 2x_1x_2 + 3x_2^2$
- 원리 (성분별 미분):
 1. x_1 에 대해 편미분: $\frac{\partial f}{\partial x_1} = 2x_1 + 2x_2$
 2. x_2 에 대해 편미분: $\frac{\partial f}{\partial x_2} = 2x_1 + 6x_2$
- 그래디언트(∇f) 분석:
 - 위 결과를 행렬 곱으로 표현하면: $\begin{bmatrix} 2 & 2 \\ 2 & 6 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$
 - 이때 계수 행렬 $\begin{bmatrix} 2 & 2 \\ 2 & 6 \end{bmatrix}$ 은 $A + A^\top$ 와 정확히 일치합니다.

$$\left(\begin{bmatrix} 1 & 2 \\ 0 & 3 \end{bmatrix} + \begin{bmatrix} 1 & 0 \\ 2 & 3 \end{bmatrix} = \begin{bmatrix} 2 & 2 \\ 2 & 6 \end{bmatrix} \right)$$
 - 따라서 $\nabla f = (A + A^\top)\mathbf{x}$ 가 성립합니다.
- 대칭 행렬($A = A^\top$)일 경우:
 - $A + A^\top$ 가 $2A$ 가 되므로, $\nabla f = 2A\mathbf{x}$ 및 $\nabla^2 f = 2A$ 로 간소화됩니다.

8.4 연쇄법칙(Chain Rule)

연쇄법칙은 여러 함수가 연결된 구조에서 입력의 변화가 최종 출력에 미치는 영향을 계산하는 도구입니다.

8.4.1 벡터 함수를 포함한 연쇄법칙(Multivariate Chain Rule with Vector Input)

변수 t (시간)가 변함에 따라 점 $\mathbf{x}(t)$ 가 공간을 이동하고, 그 점에서의 함수값 $f(\mathbf{x})$ 가 어떻게 변하는지 계산해 봅시다.

- 함수: $f(x_1, x_2) = x_1^2 + x_2^2$
- 이동 경로: $\mathbf{x}(t) = \begin{bmatrix} t \\ 2t \end{bmatrix}$
- $t = 1$ 일 때, 함수값의 변화율($\frac{df}{dt}$)은 얼마인가?

1. 현재 지점 확인: $t = 1$ 을 경로 식에 대입하면 $\mathbf{x}(1) = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$ 입니다.

2. 그래디언트(∇f) 계산:

- $\frac{\partial f}{\partial x_1} = 2x_1, \quad \frac{\partial f}{\partial x_2} = 2x_2$
- 지점 $(1, 2)$ 에서의 값: $\nabla f(1, 2) = \begin{bmatrix} 2 \\ 4 \end{bmatrix}$

3. 속도 벡터($\frac{d\mathbf{x}}{dt}$) 계산:

- $\frac{dx_1}{dt} = \frac{d}{dt}(t) = 1, \quad \frac{dx_2}{dt} = \frac{d}{dt}(2t) = 2$
- 즉, $\frac{d\mathbf{x}}{dt} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$ 입니다.

4. 연쇄법칙 적용:

$$\frac{df}{dt} = \nabla f^\top \cdot \frac{d\mathbf{x}}{dt} = [2 \quad 4] \begin{bmatrix} 1 \\ 2 \end{bmatrix} = (2 \times 1) + (4 \times 2) = \mathbf{10}$$

- 시간 t 가 아주 미세하게 증가할 때, 함수값 f 는 t 변화량의 10배만큼 빠르게 증가합니다.

8.4.2 다변수에 대한 연쇄법칙 (Chain Rule for Multivariate Functions)

입력 $\mathbf{x}$ 가 중간 단계 $\mathbf{y}$ 를 거쳐 최종 스칼라 z 에 도달하는 구조입니다.

- 관계식: $z = y_1 + y_2^2$
- 중간식: $y_1 = x_1 + x_2, \quad y_2 = x_1 x_2$
- x_1 에 대한 z 의 변화율($\frac{\partial z}{\partial x_1}$)을 구하라.

1. 성분별 계산 (Summation Notation):

$$\frac{\partial z}{\partial x_1} = \frac{\partial z}{\partial y_1} \frac{\partial y_1}{\partial x_1} + \frac{\partial z}{\partial y_2} \frac{\partial y_2}{\partial x_1} = (1 \times 1) + (2y_2 \times x_2) = 1 + 2(x_1 x_2)x_2 = 1 + 2x_1 x_2^2$$

2. 벡터/행렬 표현 (Matrix Notation)

모든 입력 변수(x_1, x_2)에 대한 변화율을 한 번에 계산합니다.

- 출력 미분: $\frac{\partial z}{\partial \mathbf{y}} = \left[\frac{\partial z}{\partial y_1}, \frac{\partial z}{\partial y_2} \right] = [1, 2y_2]$ (행 벡터, 1×2)
- 중간 미분: $\frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \begin{bmatrix} \frac{\partial y_1}{\partial x_1} & \frac{\partial y_1}{\partial x_2} \\ \frac{\partial y_2}{\partial x_1} & \frac{\partial y_2}{\partial x_2} \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ x_2 & x_1 \end{bmatrix}$ (야코비안, 2×2)
- 행렬 곱셈:
$$\frac{\partial z}{\partial \mathbf{x}} = \frac{\partial z}{\partial \mathbf{y}} \cdot \frac{\partial \mathbf{y}}{\partial \mathbf{x}} = [1 \quad 2y_2] \begin{bmatrix} 1 & 1 \\ x_2 & x_1 \end{bmatrix} = [1 + 2y_2 x_2, \quad 1 + 2y_2 x_1]$$

행렬 곱셈을 통해 x_1 뿐만 아니라 x_2 에 의한 변화율까지 한 번의 연산으로 얻을 수 있습니다.

8.4.3 텐서 함수에 대한 일반화 (Tensor-Valued Functions)

텐서 연쇄법칙의 핵심은 입력에서 출력으로 가는 모든 중간 경로(Y_j)를 거쳐가는 변화량을 합산($\sum$)하는 것입니다.

####

가장 간단한 딥러닝의 선형 층(Linear Layer) 구조를 통해 미분의 흐름을 추적해 보겠습니다.

- 입력 행렬 (X): 1×2 행렬 $\begin{bmatrix} x_1 & x_2 \end{bmatrix}$
- 중간 행렬 (Y): 가중치 W 를 곱한 결과 ($Y = XW$)
- 최종 출력 (z): Y 의 모든 성분을 더한 스칼라값 (손실 함수, Loss 역할)

1. 관계식 설정

- 가중치 행렬 $W = \begin{bmatrix} w_{11} & w_{12} \\ w_{21} & w_{22} \end{bmatrix}$ 라고 할 때,
- $Y = \begin{bmatrix} y_1 & y_2 \end{bmatrix} = \begin{bmatrix} x_1 w_{11} + x_2 w_{21} & x_1 w_{12} + x_2 w_{22} \end{bmatrix}$
- 최종 출력: $z = f(Y) = y_1 + y_2$

2. 목표: x_1 이 최종 결과 z 에 미치는 영향($\frac{dz}{dx_1}$) 구하기

공식에 따라 x_1 은 y_1 과 y_2 라는 두 갈래 길을 통해 z 에 전달합니다.

$$\frac{dz}{dx_1} = \underbrace{\frac{dy_1}{dx_1} \cdot \frac{\partial z}{\partial y_1}}_{\text{path 1}} + \underbrace{\frac{dy_2}{dx_1} \cdot \frac{\partial z}{\partial y_2}}_{\text{path 2}}$$

3. 수치 계산 단계

- 출력 쪽 미분: $\frac{\partial z}{\partial y_1} = 1, \quad \frac{\partial z}{\partial y_2} = 1$
- 중간 쪽 미분: $\frac{dy_1}{dx_1} = w_{11}, \quad \frac{dy_2}{dx_1} = w_{12}$
- 최종: $\frac{dz}{dx_1} = (w_{11} \cdot 1) + (w_{12} \cdot 1) = \mathbf{w}_{11} + \mathbf{w}_{12}$

8.5 테일러정리(Taylor's Theorem)

8.5.1 방향도함수 (Directional Derivative)

방향도함수는 다변수 공간의 한 점 $\mathbf{x}$ 에서 임의의 방향 벡터 $\mathbf{p}$ 를 따라 이동할 때 발생하는 함수값의 순간 변화율입니다.

방향도함수는 그래디언트(∇f)와 방향 벡터($\mathbf{p}$)의 내적으로 계산됩니다.

$$D(f(\mathbf{x}); \mathbf{p}) = \nabla f(\mathbf{x})^\top \mathbf{p} \quad (9)$$

그래디언트라는 전체 기울기를 내가 가고자 하는 방향 $\mathbf{p}$ 위로 투영(Projection)시킨 값입니다.

- 함수: $f(x, y) = x^2 + 3xy$

- 현재 위치: $(1, 1) \rightarrow$ 그래디언트 $\nabla f(1, 1) = \begin{bmatrix} 5 \\ 3 \end{bmatrix}$

- 이동 방향: $\mathbf{p} = \begin{bmatrix} 0.6 \\ 0.8 \end{bmatrix}$ (대각선 방향, 크기 1)

- 방향도함수 계산:

$$D(f; \mathbf{p}) = [5, 3] \begin{bmatrix} 0.6 \\ 0.8 \end{bmatrix} = (5 \times 0.6) + (3 \times 0.8) = 3.0 + 2.4 = \mathbf{5.4}$$

- x 축 방향(기울기 5)보다 약간 더 가파른 대각선 방향(기울기 5.4)으로 올라가고 있음을 알 수 있습니다.

####

8.5.2 테일러 전개 (Taylor Expansion)

일변수 함수의 테일러 전개

테일러 전개는 복잡한 다변수 함수를 현재 지점의 미분 정보(기울기, 굴곡)를 이용해 다항식으로 근사하는 기법입니다.

함수 $f(x)$ 를 특정 점 x_0 에서 다항식으로 근사합니다.

- 일차 근사: 점 x_0 에서의 접선을 긋는 것 ($f(x) \approx f(x_0) + f'(x_0)(x - x_0)$)
- 이차 근사: 점 x_0 에서의 곡률까지 반영한 포물선을 그리는 것

다변수 함수의 테일러 전개

지형 $f(x, y) = x^2 + xy + y^2$ 이 있을 때, 점 $\mathbf{x}_0 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$ 근처에서 이 지형이 어떻게 생겼는지 분석해 봅시다.

1. 함수값: $f(1, 1) = 1^2 + (1)(1) + 1^2 = \mathbf{3}$

2. 그래디언트(∇f): $\begin{bmatrix} 2x + y \\ x + 2y \end{bmatrix}$ 에 $(1, 1)$ 대입 $\rightarrow \nabla f(1, 1) = \begin{bmatrix} 3 \\ 3 \end{bmatrix}$

3. 헤시안($\nabla^2 f$): $\begin{bmatrix} \frac{\partial^2 f}{\partial x^2} & \frac{\partial^2 f}{\partial x \partial y} \\ \frac{\partial^2 f}{\partial y \partial x} & \frac{\partial^2 f}{\partial y^2} \end{bmatrix} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$ (상수 행렬)

일차 테일러 전개

현재 위치에서 $\mathbf{p} = \begin{bmatrix} 0.1 \\ 0 \end{bmatrix}$ 만큼 아주 살짝 이동했을 때의 높이를 평면으로 예측해 봅니다.

- 공식: $f(\mathbf{x}_0 + \mathbf{p}) \approx f(\mathbf{x}_0) + \nabla f(\mathbf{x}_0)^\top \mathbf{p}$
- 수치 계산:

1. 내적 계산: $\nabla f^\top \mathbf{p} = [3 \ 3] \begin{bmatrix} 0.1 \\ 0 \end{bmatrix} = (3 \times 0.1) + (3 \times 0) = 0.3$

2. 최종 예측: $3 + 0.3 = \mathbf{3.3}$

- 지금 현재 위치의 경사가 x 축 방향으로 3이니까, 그 방향으로 0.1만큼 가면 높이가 0.3 정도 높아지겠지?라고 **접평면(Tangent Plane)**을 이용해 예측한 값입니다.

이차 테일러 전개

지형의 굴곡(헤시안) 정보까지 추가하여 더 정밀하게 예측합니다.

- 공식: $f(\mathbf{x}_0 + \mathbf{p}) \approx (\text{일차 근사 결과}) + \frac{1}{2} \mathbf{p}^\top \nabla^2 f(\mathbf{x}_0) \mathbf{p}$
- 수치 계산:

$$1. \text{ 이차항 행렬 연산: } \mathbf{p}^\top \nabla^2 f \mathbf{p} = [0.1 \quad 0] \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 0.1 \\ 0 \end{bmatrix}$$

$$2. \text{ 중간 계산: } [0.1 \quad 0] \begin{bmatrix} 0.2 \\ 0.1 \end{bmatrix} = (0.1 \times 0.2) + (0 \times 0.1) = 0.02$$

$$3. \text{ 이차항 최종값: } \frac{1}{2} \times 0.02 = \mathbf{0.01}$$

- 최종 예측: $3.3(\text{일차}) + 0.01(\text{이차}) = \mathbf{3.31}$
- 결과 확인: 실제 값 $f(1.1, 1) = 1.1^2 + (1.1)(1) + 1^2 = 1.21 + 1.1 + 1 = 3.31$ 과 일치합니다.

8.5.3 평균값 정리 (Mean Value Theorem)

일변수 평균값 정리 (Univariate Case)

곡선 위의 두 점을 잇는 직선의 기울기(평균 변화율)와 똑같은 순간 기울기를 갖는 점이 두 점 사이에 적어도 하나 존재합니다.

- 수식: $\frac{\phi(\alpha_1) - \phi(\alpha_0)}{\alpha_1 - \alpha_0} = \phi'(\xi)$
- 평균 속도가 $100km/h$ 였다면, 이동 경로 중 어느 한순간에는 반드시 속도계에 정확히 $100km/h$ 가 찍히는 지점이 있다는 뜻입니다.

다변수 함수로의 확장

$f(x, y) = x^2 + y^2$ 에서 점 $\mathbf{x} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$ 으로부터 $\mathbf{p} = \begin{bmatrix} 2 \\ 0 \end{bmatrix}$ 만큼 이동하는 상황을 가정해 봅시다.

1. 좌변 (실제 함수값의 변화량):

- 출발점 높이: $f(0, 0) = 0$
- 도착점 높이: $f(2, 0) = 2^2 + 0^2 = 4$
- 실제 차이: $f(\mathbf{x} + \mathbf{p}) - f(\mathbf{x}) = 4 - 0 = \mathbf{4}$

2. 우변 (중간 지점의 그래디언트와의 내적):

- 그래디언트 식: $\nabla f = \begin{bmatrix} 2x \\ 2y \end{bmatrix}$

- 경로상의 중간 지점 $(\mathbf{x} + \alpha \mathbf{p})$: $\begin{bmatrix} 0 \\ 0 \end{bmatrix} + \alpha \begin{bmatrix} 2 \\ 0 \end{bmatrix} = \begin{bmatrix} 2\alpha \\ 0 \end{bmatrix}$ (단, $0 < \alpha < 1$)
- 중간 지점의 그래디언트: $\nabla f(2\alpha, 0) = \begin{bmatrix} 4\alpha \\ 0 \end{bmatrix}$
- 내적 계산: $\nabla f^\top \mathbf{p} = [4\alpha \quad 0] \begin{bmatrix} 2 \\ 0 \end{bmatrix} = 8\alpha$

3. 결과 확인:

- 등식 $4 = 8\alpha$ 를 만족하는 $\alpha = 0.5$ 가 존재합니다.
- 출발점(0, 0)과 도착점(2, 0)의 딱 절반 지점인 (1, 0)에서의 순간 기울기가 전체 구간의 평균적인 변화율과 정확히 일치함을 확인할 수 있습니다.

8.6 볼록성(Convexity)

볼록성은 최적화 문제에서 "지역 최솟값이 곧 전역 최솟값"임을 보장하는 매우 강력한 기하학적 성질입니다.

8.6.1 볼록집합 (Convex Sets)

볼록결합 (Convex Combination)

두 점을 잇는 선분 위의 점들을 수학적으로 표현한 것입니다.

- 예제: $\mathbf{x}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \mathbf{x}_2 = \begin{bmatrix} 4 \\ 5 \end{bmatrix}$ 라고 하자.
 - $\theta = 0.5$ 일 때: $0.5 \begin{bmatrix} 1 \\ 1 \end{bmatrix} + 0.5 \begin{bmatrix} 4 \\ 5 \end{bmatrix} = \begin{bmatrix} 2.5 \\ 3 \end{bmatrix}$ (두 점의 정중앙 점)
 - $\theta = 0.2$ 일 때: $0.2 \begin{bmatrix} 1 \\ 1 \end{bmatrix} + 0.8 \begin{bmatrix} 4 \\ 5 \end{bmatrix} = \begin{bmatrix} 3.4 \\ 4.2 \end{bmatrix}$ ($\mathbf{x}_2$ 에 더 가까운 내분점)
- θ 를 0에서 1까지 변화시키면 두 점 사이를 잇는 모든 점(선분)이 도출됩니다.

볼록집합 (Convex Set)

집합 내의 어떤 두 점을 잡아도 그 사이를 잇는 선분이 다시 집합 안에 들어와야 합니다.

- 예제 (볼록): 반지름이 2인 원 내부 집합 $C = \{\mathbf{x} \mid \|\mathbf{x}\|_2 \leq 2\}$
 - $\mathbf{x}_1 = [1, 0]^\top, \mathbf{x}_2 = [-1, 0]^\top$ 은 모두 C 에 속한다.
 - 두 점의 중점인 $[0, 0]^\top$ 역시 $\|\mathbf{0}\|_2 = 0 \leq 2$ 이므로 C 에 포함된다.
- 예제 (비볼록): 도넛 모양의 집합
 - $\mathbf{x}_1 = [2, 0]^\top, \mathbf{x}_2 = [-2, 0]^\top$ 은 집합에 속하지만, 그 사이의 $[0, 0]^\top$ 은 도넛 구멍(빈 공간)에 해당하여 집합에 속하지 않는다.

볼록껍질 (Convex Hull)

- 예제: 평면 위 세 점 $A(0, 0)$, $B(2, 0)$, $C(1, 2)$ 가 있을 때
 - 이 점들의 볼록껍질은 이 세 점을 꼭짓점으로 하는 삼각형 내부 전체 영역입니다.
- 카라테오도리 정리 적용:
 - 2차원 평면($d = 2$) 위의 어떤 복잡한 도형의 볼록껍질 안에 있는 점 P 는, 항상 그 도형의 점들 중 최대 3개($d + 1$)만 골라 만든 삼각형 내부에 위치하게 됩니다.

아핀 집합 (Affine Set)

선분이 아니라 두 점을 지나는 끝없는 직선 전체가 포함되는 집합입니다.

- 예제: 직선 방정식 $x_1 + x_2 = 1$ 을 만족하는 점들의 집합.
 - 점 $\mathbf{x}_1 = [1, 0]^\top$, $\mathbf{x}_2 = [0, 1]^\top$ 은 이 집합에 속한다.
 - $\lambda = 2$ 일 때: $2[1, 0]^\top + (1 - 2)[0, 1]^\top = [2, -1]^\top$
 - 확인: $2 + (-1) = 1$ 이므로 여전히 집합(직선)에 속합니다. (λ 가 0~1 범위를 벗어나도 성립)

원뿔 집합 (Cone)과 원뿔껍질 (Conic Hull)

원점에서 시작하여 특정 방향으로 무한히 뻗어나가는 부채꼴 모양입니다.

- 예제: 제1사분면 영역 $\mathcal{S} = \{[x_1, x_2]^\top \mid x_1 \geq 0, x_2 \geq 0\}$
 - 점 $[1, 2]^\top$ 이 $\mathcal{S}$ 에 있다면, 여기에 양수 $\alpha = 100$ 을 곱한 $[100, 200]^\top$ 도 여전히 제1사분면에 속합니다.
- 원뿔껍질: 두 벡터 $\mathbf{v}_1 = [1, 0]^\top$, $\mathbf{v}_2 = [0, 1]^\top$ 의 원뿔껍질은 이들의 양수 결합($\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2, \alpha_i \geq 0$)으로 만들어지는 제1사분면 전체가 됩니다.

8.6.2 볼록함수(Convex Functions)

볼록함수와 오목함수는 함수의 기하학적 형태를 정의하며, 최적화 문제에서 해의 존재성과 유일성을 판별하는 핵심 기준이 됩니다.

####

볼록함수 (Convex Function)

두 점을 잇는 선분을 그었을 때, 함수값이 항상 그 선분보다 아래에 있거나 같아야 합니다. 즉, "내분점의 함수값"이 "함수값의 내분점"보다 작거나 같습니다.

$f(x) = x^2$ (대표적인 볼록함수)

- 두 점 설정: $x_1 = 1, x_2 = 3$
- 함수값: $f(x_1) = 1, f(x_2) = 9$
- 내분점 ($\lambda = 0.5$)에서의 비교:
 - 좌변 (함수 내부의 평균): $f(0.5 \times 1 + 0.5 \times 3) = f(2) = 4$

- 우변 (함수값의 평균): $0.5f(1) + 0.5f(3) = 0.5(1) + 0.5(9) = 5$
- 결과: $4 \leq 5$ 이므로 볼록성 조건이 성립합니다.

오목함수 (Concave Function)

볼록함수를 뒤집어 놓은 모양($\cap$)입니다. $-f$ 가 볼록하면 f 는 오목합니다. 즉, "내분점의 함수값"이 "함수값의 내분점"보다 크거나 같습니다.

$f(x) = \ln(x)$ (대표적인 오목함수)

- 두 점 설정: $x_1 = 1, x_2 = 10$
- 함수값: $f(1) = 0, f(10) \approx 2.30$
- 비교 ($\lambda = 0.5$):
 - 중간 지점 함수값: $f(5.5) = \ln(5.5) \approx 1.70$
 - 함수값의 평균: $(0 + 2.30)/2 = 1.15$
- 결과: $1.70 \geq 1.15$ 이므로 함수값이 선분보다 위에 있는 오목함수입니다.

젠슨의 부등식 (Jensen's Inequality)

볼록함수의 정의를 여러 점(k 개) 또는 확률 변수로 확장한 것입니다. "기댓값의 함수값은 함수값의 기댓값보다 작거나 같다"는 원리를 담고 있습니다.

$f(x) = x^2$ 이고, x 가 1과 3이 나올 확률이 각각 0.5인 상황이라고 합시다.

- 기댓값의 함수값 ($f(\mathbb{E}[x])$):
 - 평균 $\mathbb{E}[x] = (1 \times 0.5) + (3 \times 0.5) = 2$
 - $f(2) = 4$
- 함수값의 기댓값 ($\mathbb{E}[f(x)]$):
 - 각 지점의 함수값: $f(1) = 1, f(3) = 9$
 - 평균: $(1 \times 0.5) + (9 \times 0.5) = 5$
- 결과: $4 \leq 5$ 가 성립합니다.

볼록함수의 최적화 (Minimizing a Convex Function)

볼록함수에서 최적화를 수행할 때, 국소적 정보만으로 전역적인 정답을 찾을 수 있음을 보장하는 정리입니다.

함수 $f(x) = (x - 2)^2$ (볼록 함수)를 예로 들어 봅시다.

- 국소 최적해(Local Minimizer):
 - $x = 2$ 근처를 살펴보면, $f(1.9) = 0.01, f(2) = 0, f(2.1) = 0.01$ 입니다.
 - $x = 2$ 는 주변에서 가장 낮은 지점이므로 국소 최적해입니다.
- 전역 최적해(Global Minimizer):

- 이 함수는 아래로 볼록한 포물선이므로, $x = 2$ 보다 더 낮은 값을 갖는 지점은 없습니다. 따라서 전역 최적해입니다.
- 정계 조건(Stationary Condition):
 - $f'(x) = 2(x - 2)$ 입니다.
 - $x = 2$ 를 대입하면 $f'(2) = 0$ 이 됩니다. 즉, 기울기가 0인 지점입니다.